



UNIVERSIDAD FAVALORO

FACULTAD DE INGENIERIA Y CIENCIAS EXACTAS Y NATURALES

PROYECTO FINAL

Dinámica de los procesos de traducción: una nueva ventana hacia la neurocognición bilingüe

Comisión Evaluadora:	

Director del Proyecto:	Dra. Ing. Eugenia Hesse	Alumno:	Gonzalo Nicolás Pérez
Carrera:	Ingeniería Biomédica	Fecha:	08/03/2021

[Firma integrante N° 1 de CE]	[Firma integrante N° 2 de CE]	[Firma integrante N° 3 de CE]

[Firma integrante N° 1 de JPF]	[Firma integrante N° 2 de JPF]

Tabla de contenidos

Introducción.....	3
Herramientas neurocientíficas	5
Electroencefalografía	5
Métodos de aprendizaje estadístico.....	12
Materiales y Métodos	16
Participantes.....	16
Experimento.....	16
Análisis de datos conductuales	18
Registro y preprocesamiento de EEG	19
Oscilaciones	19
Correlaciones entre RT y patrones oscilatorios.....	23
Conectividad	23
Métodos de aprendizaje estadístico	27
Predictores (<i>features</i>) considerados	27
Análisis de Discriminante Lineal	28
Análisis de Discriminante Cuadrático.....	30
Clasificación por K vecinos más cercanos	30
Clasificador de vectores de soporte lineal.....	31
Resultados.....	33
Análisis conductuales	33
Precisión.....	33
Tiempos de reacción.....	33
Oscilaciones	33
Correlación entre tiempos de reacción y potencia espectral	34
Conectividad	35
Métodos de aprendizaje estadístico	37
Discusión	39
Conclusiones.....	45
Referencias	45
Anexo	49
Glosario	49

Introducción

El campo de las neurociencias ha experimentado un avance considerable en el último tiempo. En particular, existe un creciente interés científico por el bilingüismo [1-3], ya que el aprendizaje de una lengua no nativa modifica la forma en la que el cerebro procesa la información léxica, gramática y ejecutiva [4]. Actualmente, más de la mitad de la población mundial domina al menos dos lenguas, hecho que obedece a varios factores [4]. En primer lugar, se estima que existen unas 7000 lenguas en el mundo, de modo que la relación entre la cantidad de lenguas y la de países es de aproximadamente 35 a 1, por lo cual en muchos países coexisten al menos dos lenguas, superando el centenar en algunos casos. En segundo lugar, la preponderancia del bilingüismo es consecuencia de los fenómenos migratorios: debido al aumento de la inmigración en algunos países, el número total de hablantes de ciertas lenguas supera por mucho al de sus hablantes nativos. Por último, las comunicaciones internacionales y los fenómenos de globalización facilitan, y muchas veces exigen, un buen desenvolvimiento en el procesamiento de lenguas no nativas. El estudio del bilingüismo permite profundizar nuestro conocimiento respecto de la forma en la que se estructuran y sustentan las bases neurales que dan origen a la producción y comprensión de una lengua no nativa, particularmente relevantes para la implementación de mejores prácticas docentes en la enseñanza de lenguas extranjeras [4].

El concepto de bilingüismo en el sentido en el que se utilizará aquí es aquel propuesto por el Dr. François Grosjean: “son bilingües aquellas personas que usan dos (o más) lenguas (o dialectos) en su vida cotidiana y que desarrollan competencias en sus lenguas en la medida en que sus necesidades lo requieren”. Esta definición admite la existencia de diferencias en el nivel con el que una persona bilingüe maneja su lengua nativa (L1) y alguna de sus lenguas no nativas (L2). Además, considera la posibilidad de que tales habilidades se modifiquen a lo largo de la vida de la persona bilingüe como producto de su inmersión en contextos sociales y/o laborales diversos. Es decir, la definición contempla que la competencia en L2 es dinámica a lo largo de la vida y puede presentar variaciones para algunas dimensiones o usos del idioma.

A pesar de la prevalencia mundial del bilingüismo y su relevancia, este aspecto de la psicolingüística ha sido ignorado por la mayoría de los textos generales sobre el

tema, que lo consideraron históricamente como un caso de estudio particular cuya utilidad era únicamente la de probar las teorías generales sobre el procesamiento del lenguaje. No obstante, como destaca Cook [5], en la traducción hecha por García [4], “si se toma al monolingüismo como la condición normal de la humanidad, podrá tratarse a los usuarios de lenguas extranjeras como notas al pie de la lingüística. Sin embargo, dado que la mayoría de las personas aprenden o usan una L2, la excepción la constituyen los monolingües, tanto a nivel estadístico como en términos de potencial humano”.

Aunque el bilingüismo aún es un área poco explorada, el campo de las neurociencias es el que más ha colaborado en la caracterización de los procesos de adquisición y manejo del lenguaje. Su carácter interdisciplinario posibilita el acercamiento al fenómeno desde perspectivas distintas y complementarias. Además, se utilizan métodos y herramientas que permiten el análisis cuantitativo y riguroso de modelos y teorías psicolingüísticas. En este sentido, el abordaje neurocientífico ha contribuido fuertemente a la caracterización del procesamiento léxico en bilingües, particularmente en lo que respecta a procesos de lectura y traducción de palabras. Los experimentos que abordan estos aspectos de la psicolingüística han sido fundamentales para entender la estructura, organización y adaptabilidad del sistema léxico-semántico bilingüe [4].

No obstante, la mayoría de la evidencia de la que se dispone al respecto es, o bien exclusivamente comportamental, o basada en estudios de neuroimágenes, como la resonancia magnética funcional (fMRI). Además, el estudio del efecto de direccionalidad en tareas de traducción (esto es, el fenómeno de asimetría entre traducciones efectuadas desde y hacia L1) ha sido sistemáticamente ignorado por la literatura neurocientífica, particularmente la que involucra el análisis de señales de electroencefalografía (EEG). Esto representa un déficit importante para el estudio de la neurocognición bilingüe, puesto que la EEG cuenta con una resolución temporal que permite captar dinámicas sutiles del procesamiento bilingüe, que escapan a otras técnicas de neuroimágenes, más ampliamente utilizadas en el campo. La ausencia de resultados obtenidos a partir del análisis de EEG en este ámbito dificulta, también, la integración de los descubrimientos hechos en esta área con los obtenidos en otros campos dentro de las neurociencias cognitivas.

En este proyecto, se presenta un estudio neurocientífico que tiene como objetivo indagar sobre algunos aspectos vinculados a la temática bilingüe, particularmente en lo

que respecta a los patrones de actividad diferenciales que surgen como respuesta a la lectura en L1 y L2, por un lado, y, lo que es aún más novedoso, durante el procesamiento de tareas de traducción de L1 a L2 y viceversa. Para lograr este objetivo, se hará uso de técnicas de análisis de EEG que incluyen métodos clásicos y fundacionales de la electrofisiología cognitiva y otros más novedosos que han sido, hasta ahora, escasamente utilizados para caracterizar las dinámicas del procesamiento bilingüe antes indicadas. Además, el análisis estadístico empleado también hace uso de método más recientes, de modo que el abordaje propuesto en este trabajo representa un aporte significativo a nivel metodológico para el estudio de la neurocognición bilingüe.

Herramientas neurocientíficas

El progreso de las neurociencias, y de la neurolingüística en particular, se vio impulsado por el desarrollo de técnicas no invasivas que posibilitan el estudio de los procesos cognitivos que tienen lugar durante la realización de tareas específicas. Típicamente, se analizan cambios en la dinámica de la actividad cerebral que surgen como respuesta a estímulos seleccionados para el estudio de algún aspecto específico de la cognición. A continuación, se presenta una de las técnicas de registro de actividad cerebral no invasiva más extensamente utilizada en el área, y se detallan algunas de las herramientas de análisis que permiten extraer conclusiones a partir de la actividad registrada.

Electroencefalografía

La electrofisiología cognitiva es una rama de las neurociencias que estudia de qué manera las funciones cognitivas, como la percepción, memoria, lenguaje, las emociones y la cognición social, modulan la actividad eléctrica de distintas poblaciones de neuronas [6]. De todas las técnicas no invasivas existentes, la EEG es una de las más extensamente utilizadas en el campo. Presenta una resolución temporal del orden de los milisegundos, una característica fundamental para el estudio de procesos cognitivos que acontecen en esa escala temporal. Entre otras ventajas, se destacan su portabilidad, bajo costo y la posibilidad de realizar diversos tipos de análisis sobre los datos adquiridos para explorar múltiples aspectos de las bases neurales de la cognición, como estudios de potenciales evocados (ERP), latencia, polaridad, topografía, dinámica oscilatoria y conectividad.

El registro de EEG consiste en colocar un gorro donde se conectan electrodos (entre 64 y 128) con cables que transmiten la información registrada a una computadora. Estos electrodos registran fluctuaciones de voltaje que son reflejo directo de los fenómenos biofísicos que ocurren a nivel neuronal. Las oscilaciones observadas en las señales registradas son consecuencia de aquellas que tienen lugar en la corteza cerebral [6]. Un electrodo de EEG ubicado sobre el cuero cabelludo registra la actividad de un grupo de entre cien mil y mil millones de neuronas, equiparable aproximadamente a 10 cm^2 de superficie cortical [7]. Las señales registradas por esos electrodos tienen su origen en las interacciones eléctricas entre grupos de neuronas. Esta comunicación neuronal está mediada por dos tipos de impulsos eléctricos: (i) los potenciales de acción, que transmiten información eléctrica desde el cuerpo neuronal a lo largo de su axón, y (ii) los potenciales postsinápticos, que se originan cuando los neurotransmisores emitidos por la neurona presináptica se unen a sus correspondientes receptores en la neurona postsináptica, desencadenando la apertura o cierre de canales iónicos en esta última. Mientras que los potenciales de acción son extremadamente rápidos (del orden de unos pocos milisegundos), lo que hace prácticamente imposible su registro con métodos no invasivos, los potenciales postsinápticos pueden durar decenas o cientos de milisegundos y generan dipolos eléctricos (dos cargas eléctricas de igual magnitud, con cargas opuestas -una positiva y otra negativa-, separadas espacialmente). Si se produce una cantidad considerable de potenciales postsinápticos, sus efectos se suman, y el resultado puede registrarse con un electrodo en la superficie del cuero cabelludo [8]. Los sensores de EEG capturan, precisamente, los patrones temporales de estas fluctuaciones de voltaje.

Técnicas de análisis de EEG

A partir de las señales de EEG obtenidas, es posible extraer información sobre la dinámica de los procesos neurocognitivos que las originaron. A grandes rasgos, las técnicas de procesamiento de estas señales pueden agruparse en dos grandes enfoques. Uno de ellos, más tradicional, es el enfoque *localizacionista*, que busca determinar las regiones cerebrales específicas involucradas durante el procesamiento de ciertas tareas, de forma individual. A esta categoría corresponden los análisis de ERP y de dinámica oscilatoria; por otro lado, el enfoque *distribuido* pretende identificar redes que intercambian información entre sí y que, de esta manera, participan de forma coordinada en el procesamiento de una tarea. Este enfoque agrupa diversos métodos, denominados

genéricamente métodos de *conectividad*, que cuantifican el intercambio de información entre regiones cerebrales, basándose en distintos principios.

Potenciales Evocados

Una forma de estudiar la dinámica cerebral es a través de los llamados potenciales evocados. En este enfoque, las modulaciones en la actividad eléctrica registrada por los electrodos, y generada como respuesta a un estímulo específico, son promediadas a lo largo de sucesivos ensayos pertenecientes a la misma categoría. Esto hace que se eliminen las fluctuaciones aleatorias que no están asociadas al procesamiento de la tarea en cuestión [8]. De esta manera, teóricamente sobreviven aquellas diferencias de potencial que se mantienen a lo largo de los sucesivos ensayos, y que, por tanto, están directamente ligados al procesamiento del estímulo. Normalmente, esto origina un patrón de deflexión oscilante, con picos de potencial positivos y negativos (respecto a la actividad basal, es decir, previa a la aparición del estímulo de interés), denominados *potenciales evocados*. La nomenclatura utilizada para hacer referencia a estos patrones de actividad consiste en colocar la letra N o P (dependiendo de si el pico de potencial es positivo o negativo), seguido de un número que indica, en milisegundos, el instante de tiempo relativo a la presentación del estímulo en el que tuvo lugar ese pico.

En relación con los estudios sobre bilingüismo, se ha observado que la actividad eléctrica evocada por la traducción de palabras cognadas (es decir, aquellas que muestran un alto grado de similitud morfológica entre ambos idiomas) evidencia patrones diferenciales cuando la palabra traducida es concreta, en comparación con lo que se observa durante la traducción de palabras abstractas, también cognadas. En particular, la traducción de palabras concretas cognadas origina un patrón de deflexión similar al potencial evocado N400 que es máximo en regiones centro-temporales, moderado en registros frontales, y despreciable en zonas parietales [9]. A modo de ilustración, la Figura 1 muestra un potencial evocado N400 generado por el procesamiento de oraciones con incongruencias semánticas.




Figura 1. Modificada de [8]. Ejemplo de un potencial evocado N400, registrado en un electrodo central durante el procesamiento de oraciones en las que una de las palabras es semánticamente incongruente con el resto de la oración.

Sin embargo, los análisis de ERP presentan una desventaja importante: puesto que se obtienen a partir del promedio de la actividad eléctrica registrada en ensayos sucesivos, la respuesta asociada al estímulo no solo debe coincidir en tiempo entre los diferentes ensayos, sino también en fase, es decir, el punto de inicio de un ciclo de la onda (medida en grados o radianes). En caso de que los ensayos no sean consistentes en fase, los efectos registrados desaparecen al ser promediados (ver Figura 2). Aunque la evidencia recabada mediante análisis de ERP es vasta, este tipo de estudios solo provee información sobre procesos en los que haya coincidencia de fase, limitando así el estudio de otras dimensiones con potencial información sobre el procesamiento neuronal subyacente.

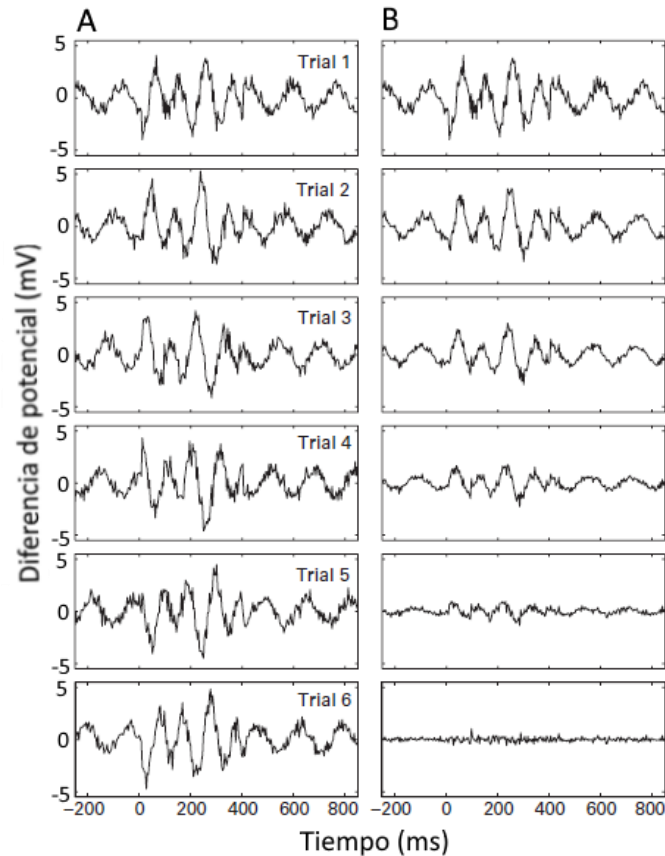


Figura 2. Modificada de [6]. Datos simulados que ponen de manifiesto la principal desventaja de los análisis de potenciales evocados. En la columna A se muestra la actividad eléctrica registrada por un electrodo en ensayos sucesivos. En la columna B se observa el potencial evocado que surge a partir del promedio de la actividad eléctrica desde el primer ensayo hasta el que corresponde a la misma fila en la columna A. Puede observarse que, al cabo de 6 ensayos, el potencial evocado es prácticamente nulo, debido a la falta de consistencia en fase de la actividad eléctrica en los ensayos sucesivos.

Oscilaciones – Análisis de frecuencia

Las técnicas de análisis de tiempo-frecuencia permiten rodear la limitación inherente a los análisis de ERP respecto de la necesaria sincronía en fase de la respuesta entre ensayos. A través de estas técnicas es posible caracterizar todos los componentes oscilatorios (frecuencia, amplitud y fase) a lo largo del tiempo y en múltiples bandas de frecuencia, hecho valioso si se tiene en cuenta que la actividad cerebral es fuertemente oscilatoria. Estas oscilaciones reflejan fluctuaciones rítmicas en la excitabilidad de grupos de neuronas, que ocurren en escalas espacio-temporales muy diversas: desde ondas con una periodicidad de decenas de segundos durante el sueño profundo [10] hasta oscilaciones ultrarrápidas con una periodicidad de unos pocos milisegundos en regiones

de la corteza somatosensitiva [11]. La potencia espectral de una señal, que se define como el cuadrado de la amplitud de la oscilación, es una medida de la energía contenida en una banda de frecuencia. Algunos estímulos evocan una mayor potencia espectral comparada con la actividad basal, fenómeno conocido como *sincronización*. En contraposición, un proceso de *desincronización* implica una disminución en la potencia espectral como respuesta a un estímulo.

Los ritmos cerebrales normalmente se agrupan en bandas de frecuencia específicas. Las más relevantes son las bandas delta (1-4 Hz), theta (5-7 Hz), alfa (8-13 Hz), beta (14-30 Hz), gamma baja (31-80 Hz) y gamma alta (81-150 Hz). Es pertinente destacar que en la literatura no existen límites precisos para algunos de estos rangos. Por otro lado, la actividad en una banda de frecuencia puede ocurrir simultáneamente con la actividad en otras bandas de frecuencia. Por lo tanto, si diferentes neuronas presentan actividad en distintas frecuencias, múltiples redes neuronales funcionalmente diversas pueden coexistir espacialmente y pueden ser disociadas a partir de sus patrones espectrales.

Debido a la alta resolución temporal de la EEG, es posible observar cambios en los patrones de sincronización y desincronización que ocurren durante decenas o cientos de milisegundos. Estas dinámicas corticales complejas ocurren 1 a 2 órdenes de magnitud más rápidamente que las respuestas registradas por otros métodos no invasivos, como fMRI, y, como se indicó previamente, pueden perderse durante el proceso de promediado de la señal de EEG en el dominio temporal, típica de los análisis clásicos de potenciales evocados.

Varios estudios han aportado evidencia experimental sobre el rol de distintas bandas de frecuencia en ciertos procesos neurocognitivos. Por ejemplo, para procesos neurolingüísticos, la banda theta (4-7 Hz) y el rango superior de alfa (10-13 Hz) están asociadas al procesamiento de estímulos perceptuales [12]. Por otro lado, el reconocimiento, la codificación y la recuperación de palabras están asociados con modulaciones en la banda theta, los rangos inferiores de alfa (8-10 Hz) y beta (13-20 Hz), y el rango superior de beta (20-30 Hz). Además, se ha mostrado que la potencia de la banda theta se incrementa continuamente durante el procesamiento de una oración correcta, lo que sugiere un aumento progresivo de la carga de memoria de trabajo [13]. En cambio, cuando una oración presenta incongruencias sintácticas o semánticas, la potencia en las bandas alfa y beta disminuye [14]. En lo que respecta al bilingüismo,

también existen estudios que revelan modulaciones en bandas de frecuencia específicas durante el desarrollo de tareas de lectura y traducción. Por ejemplo, se ha observado un patrón de actividad que involucra desincronización en la banda theta, fundamentalmente en regiones parietales, y el rango superior de alfa, predominantemente en regiones frontales, durante la traducción exitosa de palabras poco frecuentes, en comparación con el proceso de traducción de palabras más frecuentemente utilizadas [15].

Los ejemplos citados muestran que la dinámica oscilatoria de las señales de EEG está vinculada estrechamente con procesos cognitivos concretos. Este fenómeno está respaldado por evidencia empírica que surge de numerosos estudios sobre diversos fenómenos neurocognitivos, en general, y neurolingüísticos, en particular. En el presente trabajo se hará uso de esta herramienta de análisis extensamente validada.

Conectividad

En las últimas dos décadas, ha ocurrido un cambio de foco con respecto a la forma de estudiar el funcionamiento del cerebro. Mientras que, como se indicó anteriormente, los métodos *localizacionistas* tradicionales se concentran en determinar cuáles son las regiones involucradas en un determinado proceso, el enfoque *distribuido* utiliza métodos de conectividad como herramienta para comprender de qué manera distintas regiones interactúan entre sí durante un proceso cognitivo [6]. Aquí se usará el concepto de conectividad en un sentido bivariado, definida como el conjunto de procesos vinculados con el intercambio de información entre dos regiones cerebrales. No obstante, existe un creciente interés en extender esta definición para incluir interacciones entre varias regiones simultáneamente, de una forma multivariada. Sin embargo, los modelos bivariados presentan ventajas en cuanto a una mayor facilidad de interpretación, y análisis cuantitativo y estadístico.

Desde una perspectiva bivariada, se pueden distinguir tres tipos de conectividad cerebral: (i) estructural, que se refiere al conjunto de conexiones físicas que vinculan elementos neurales, como el caso de las sinapsis; (ii) funcional, que describe patrones de interacciones dinámicas, y determina que dos regiones están conectadas funcionalmente si sus dinámicas son estadísticamente dependientes entre sí; y (iii) efectiva, que pone de manifiesto una serie de efectos causales entre elementos neurales, a menudo inferidos en base a precedencias temporales en las señales registradas [16]. Es importante destacar que la conectividad funcional se refiere a la presencia de variaciones conjuntas (lineales o no

lineales) de la actividad en distintas redes neuronales, mientras que la conectividad efectiva hace referencia a una influencia causal de una red neuronal sobre la actividad de otra [17]. Por lo tanto, la distinción entre conectividad funcional y efectiva es análoga a la distinción existente entre correlación y causalidad.

Desde una perspectiva metodológica, el término *conectividad* hace referencia a cualquier análisis en el que se utiliza alguna métrica que cuantifica el intercambio de información entre dos señales durante un determinado periodo de tiempo. Mayoritariamente, este concepto se refiere a las señales provenientes de dos electrodos diferentes, pero también puede hacer referencia a dos señales del mismo electrodo o a múltiples señales de múltiples electrodos. En este trabajo se llevará a cabo un análisis de conectividad funcional a partir de una herramienta conocida como información simbólica mutua ponderada (*wSMI*, *weighted symbolic mutual information*) [18], que ya ha sido utilizada con éxito en trabajos previos en el campo de las neurociencias cognitivas [18-22].

Métodos de aprendizaje estadístico

Gracias al creciente poder de cómputo del que se dispone en la actualidad, es posible implementar algoritmos capaces de manejar grandes volúmenes de datos y extraer conclusiones y relaciones entre variables, así como también hacer predicciones cada vez más certeras a partir de esos datos. Por este motivo, la ciencia en general ha mostrado un interés creciente hacia el desarrollo de algoritmos de aprendizaje estadístico, y las neurociencias no ha sido la excepción. De hecho, el uso de estos métodos ha mantenido un ritmo de crecimiento continuo en el ámbito neurocientífico durante los últimos 20 años [23].

La mayoría de los problemas de aprendizaje estadístico se engloban en una de dos categorías: supervisado o no supervisado [24]. En el caso de los problemas de aprendizaje supervisado, para cada observación x_i , $i = 1, 2, \dots, N$, existe un valor conocido de la variable dependiente y_i . Por el contrario, en los métodos de aprendizaje no supervisado, la respuesta y_i es desconocida. En otras palabras, en los métodos de aprendizaje supervisado, cada entrada tiene asociada un valor o etiqueta conocida, mientras que esta información está ausente en el caso de los métodos de aprendizaje no supervisado. En

estos últimos, se busca comprender la relación entre los parámetros de entrada e identificar patrones en los datos.

Dentro de los métodos de aprendizaje supervisado existe una diferenciación adicional, en términos de la forma que toma la variable dependiente. Si se trata de una variable cuantitativa (es decir, que toma valores numéricos en un dominio continuo), el problema en cuestión es de regresión, mientras que, si la variable es cualitativa (es decir, que toma valores discretos dentro de un conjunto de K clases posibles), se trata de un problema de clasificación [24].

En problemas de clasificación, se designa con G a la variable dependiente, que puede tomar valores entre 1 y K , cada uno de los cuales corresponde a una clase distinta. Estos algoritmos permiten decodificar los procesos cognitivos a través de los patrones presentes en las señales registradas. Primero, se entrena un clasificador \hat{G} (un estimador de la variable dependiente G), utilizando un subconjunto de datos X (conjunto de entrenamiento) para asociar patrones de actividad cerebral con las respectivas condiciones experimentales. Durante el proceso de entrenamiento, el clasificador establecerá un criterio de clasificación, o frontera de decisión (en inglés, *decision boundary*), que logre separar los patrones de actividad cerebral en tantos grupos como condiciones experimentales distintas existan. Posteriormente, el clasificador ya entrenado es utilizado para predecir la condición experimental a la que corresponde un nuevo conjunto de datos que fue excluido durante el proceso de entrenamiento (conjunto de prueba). Si el clasificador logra un desempeño significativamente mejor que el que se esperaría por azar, se considera capaz de generalizar satisfactoriamente los patrones aprendidos durante el entrenamiento. Esto permite concluir que los patrones de actividad cerebral contienen información para distinguir la condición experimental que les dio origen.

Existe una gran variedad de clasificadores, cada uno de los cuales presenta ventajas y desventajas, muchas veces asociadas a determinadas características del conjunto de datos con el que se está trabajando. Algunos de ellos, llamados paramétricos, imponen condiciones sobre la distribución de probabilidad del conjunto de datos de entrada X (que, en este contexto, se toma como una variable aleatoria), mientras que para los no paramétricos no es necesario conocer la distribución de probabilidad de los datos observados. Naturalmente, cuando los datos registrados responden a la distribución de probabilidad propuesta por el clasificador, su desempeño es mejor que el de un

clasificador no paramétrico; por el contrario, cuando la suposición es incorrecta, los métodos no paramétricos generan mejores resultados.

Además, existen distintos tipos de clasificadores en base a los criterios utilizados para definir las fronteras de decisión, que pueden ser funciones lineales o no lineales de las entradas. Los clasificadores lineales son más simples, pero poseen un grado más alto de sesgo (en inglés, *bias*) que sus contrapartes no lineales, es decir, plantean suposiciones más estrictas sobre los datos analizados. Si la separación entre los datos no responde a una función lineal, el desempeño del clasificador en el conjunto de prueba es deficiente, fenómeno conocido como subajuste (en inglés, *underfitting*). Por el contrario, los clasificadores no lineales favorecen fronteras de decisión más complejas, de tal manera que ajustan muy efectivamente los datos de entrenamiento, pero su desempeño es pobre con los datos del conjunto de prueba. Este fenómeno se conoce como sobreajuste (en inglés, *overfitting*), y se dice que los clasificadores que incurren en este error poseen alta varianza. La relación de compromiso entre sesgo y varianza ha sido, y sigue siendo, objeto de muchos análisis teóricos de métodos de aprendizaje estadístico.

Por último, los clasificadores también pueden ser binarios, si separan datos pertenecientes únicamente a dos clases distintas, o multiclase (en inglés, *multiclass*), si separan datos correspondientes a tres o más clases distintas. En este trabajo se hará uso de clasificadores binarios, puesto que se compararán condiciones experimentales tomadas de a pares.

Curva de Característica Operativa del Receptor (ROC)

La curva de característica operativa del receptor (ROC, en inglés: *Receiver Operating Characteristic Curve*) es un método frecuentemente utilizado para evaluar el desempeño de un clasificador. Se trata de un gráfico que toma en consideración los errores que puede cometer un clasificador, y se obtiene modificando progresivamente el umbral de clasificación [25]. En la práctica, un clasificador binario, como los utilizados en el presente trabajo, puede cometer dos tipos de errores: asignar erróneamente un elemento de la clase 1 a la clase 2, o viceversa. Una entrada se clasifica como “positiva” si el resultado del clasificador aplicado a dicha entrada supera cierto umbral predefinido. De lo contrario, la entrada se clasifica como negativa.

Para construir las curvas ROC de un clasificador, se definen dos medidas: sensibilidad y especificidad. La sensibilidad (también llamada razón de positivos verdaderos; en inglés, *true positive rate: TPR*) de un clasificador se define como la probabilidad de clasificar correctamente una entrada de la clase positiva:

$$\text{Sensibilidad: } TPR = \frac{TP}{P} \quad [1]$$

donde P es la cantidad total de elementos de la muestra clasificados como positivos, de los cuales TP fueron clasificados correctamente como tales. Por otro lado, la especificidad (o razón de negativos verdaderos; en inglés, *true negative rate: TNR*) se define como la probabilidad de clasificar correctamente una entrada negativa:

$$\text{Especificidad: } TNR = \frac{TN}{N} \quad [2]$$

donde N es la cantidad total de elementos clasificados como negativos, de los cuales TN fueron clasificados correctamente. Al modificar el umbral de decisión, cambian los valores de TPR y TNR del clasificador.

La curva ROC de un clasificador representa un gráfico de sensibilidad (eje vertical) vs. 1-especificidad (eje horizontal), o tasa de falsos negativos, para distintos valores del umbral de clasificación. Un buen clasificador es aquel que tiene una tasa alta de verdaderos positivos (idealmente, 1) con una tasa baja de falsos negativos (idealmente, 0). El desempeño de un clasificador, para todos los posibles valores de umbral de clasificación, queda determinado por el área bajo la curva ROC (*area under the curve: AUC*). A mayor área bajo la curva, mejor es el desempeño del clasificador. El valor máximo de área bajo la curva que puede obtener un clasificador es 1, mientras que un área de 0.5 en una clasificación binaria representa un proceso que no es más efectivo que lo que se obtendría por azar.

Validación cruzada de 10 pasos

Una estrategia extensamente utilizada para obtener una curva ROC representativa del proceso de clasificación consiste en aplicar una validación cruzada de 10 pasos (*10-folds cross-validation*). Este proceso implica dividir el conjunto de entrenamiento en 10 partes iguales, entrenar al clasificador en 9/10 del conjunto original y tomar el 1/10 restante como conjunto de prueba. En cada paso se obtiene la curva ROC del clasificador, así como su área bajo la curva. Al ejecutar ese paso 10 veces en forma secuencial, se

asegura que todos los elementos del conjunto de entrenamiento sean, en un momento u otro, considerados parte del conjunto de prueba. La curva ROC final se obtiene a partir del promedio de las curvas ROC generadas en cada paso de validación. También se determinan el área bajo la curva media y su desvío estándar como métricas de desempeño del clasificador en cuestión. Este procedimiento es muy común, principalmente cuando se dispone de un conjunto de entrenamiento relativamente pequeño.

Materiales y Métodos

Participantes

La muestra incluyó 14 sujetos argentinos, hablantes nativos de español (L1), que aprendieron inglés (L2) a través de un programa de educación formal: alumnos avanzados de un Profesorado de inglés, o bien profesores de inglés ya recibidos, pero sin entrenamiento formal en tareas que impliquen reformulación interlingüística (traducción y/o interpretación simultánea). Todos ellos eran diestros y tenían visión normal o corregida, y ninguno reportó un historial de antecedentes neurológicos o psiquiátricos. Además, completaron un cuestionario en el que brindaron información demográfica y referida a los idiomas considerados en el experimento, con el objetivo de comprobar que los participantes fueran representativos de esta población. En primer lugar, indicaron su género, edad, edad de adquisición de L2 y años de estudio de L2. Posteriormente, se les pidió que indicaran su nivel de competencia en ambos idiomas, así como también el nivel de competencia en tareas de interpretación en las direcciones $L1 \rightarrow L2$ y $L2 \rightarrow L1$, en una escala de 1 (nula) a 7 (óptima). Estos dos extremos denotan completa incapacidad para desarrollar incluso tareas básicas de traducción, y alta capacidad para desempeñarse en ese ámbito con facilidad y de forma rutinaria, respectivamente. Además, los participantes debieron estimar la cantidad de horas semanales dedicadas al consumo de información multimedia (por ejemplo, televisión, textos escritos, radio) en cada idioma.

Experimento

El experimento consistió en dos tareas previamente reportadas [26], una de lectura y otra de traducción, en las que se emplearon 192 pares de sustantivos semánticamente

equivalentes. Los estímulos en español fueron distribuidos en tres bloques de 64 palabras cada uno (SP1, SP2, SP3), al igual que los estímulos en inglés (EN1, EN2, EN3). Los bloques SP1, SP2, EN1 y EN2 fueron utilizados para las tareas de traducción, mientras que los bloques SP3 y EN3 se reservaron para tareas de lectura. Se controlaron las variables de los estímulos entre tareas combinando los bloques SP1 y SP2 en un solo bloque de traducción en español (SPT). Por el mismo motivo, se agruparon los bloques EN1 y EN2 en un único bloque de traducción en inglés (ENT).

Los ítems en cada bloque fueron vinculados con sus equivalentes en el otro idioma. Cada uno de los seis bloques contenía 32 sustantivos concretos, entre cognados (por ejemplo, *paper*, papel) y no cognados (por ejemplo, *table*, mesa) y 32 abstractos, entre cognados (por ejemplo, *comedy*, comedia) y no cognados (por ejemplo, *punishment*, castigo). No se evidenciaron diferencias significativas entre la cantidad de sílabas de las palabras que formaban cada bloque (SPT vs. ENT: $p = 0.99$; SP3 vs. EN3: $p = 0.99$; SPT vs. SP3: $p = 1$; ENT vs. EN3: $p = 0.99$). Análogamente, todos los bloques fueron emparejados por rango (orden de aparición en el corpus respectivo), para cada lenguaje individual y también entre lenguajes (SPT vs. ENT: $p = 0.97$; SP3 vs. EN3: $p = 0.99$; SPT vs. SP3: $p = 0.99$; ENT vs. EN3: $p = 0.98$). Todos los datos de rango y frecuencia fueron obtenidos de [27, 28]. Los estímulos fueron distribuidos aleatoriamente en cada bloque.

Los participantes fueron evaluados individualmente en una habitación con iluminación tenue, sentados detrás de un escritorio, frente a un monitor. A través de un programa escrito en Python, haciendo uso de la librería Pygame, se presentaron las instrucciones y los estímulos, y se registró el tiempo de reacción (RT) de cada ensayo. Antes del experimento, los voluntarios recibieron instrucciones de forma oral, anticipando las que aparecerían escritas en la pantalla durante la ejecución de las tareas. Un examinador monitoreó el desempeño de los participantes. Cada uno de los sujetos realizó cuatro tareas en total: lectura en L1 (*L1 reading: L1R*), lectura en L2 (*L2 reading: L2R*), traducción hacia atrás (*backward translation: BTR*, de L2 a L1) y traducción hacia adelante (*forward translation: FTR*, de L1 a L2). La secuencia de tareas fue aleatorizada entre participantes, para que ninguno de ellos las ejecutara en el mismo orden. Todas las tareas de lectura (L1R, L2R) usaron los bloques EN3 y SP3. Para evitar sesgos de lenguaje entre tareas, se alternaron los otros bloques (EN1, EN2, SP1, SP2) entre los participantes, de modo que los pares equivalentes en BTR no fueran los mismos que los usados en FTR.

(es decir, si un sujeto realizó la tarea de BTR con el bloque EN1, la tarea de FTR fue ejecutada con el bloque SP2).

Durante cada una de las tareas, los participantes debían, o bien leer en voz alta (en L1R y L2R), o bien traducir (en BTR y FTR) las palabras que aparecían en la pantalla tan rápida y precisamente como pudieran. Cada prueba comenzó con una cruz de fijación en el centro de la pantalla, visible durante los 300 ms previos a la aparición de la palabra, que, a su vez, permanecía en el centro de la pantalla durante 200 ms, en letras blancas (fuente: Times New Roman; tamaño: 70), contra un fondo negro. Los sujetos debían presionar una tecla cuando se sintieran listos para articular sus respuestas. Al hacerlo, se registraba el RT del ensayo y, a continuación, se procedía a la presentación del siguiente estímulo. Inmediatamente después de presionar esa tecla, los participantes debían dar sus respuestas en voz alta. Los intervalos entre ensayos sucesivos fueron suficientemente largos como para evitar la superposición temporal entre la respuesta y la presentación del siguiente estímulo. Durante la ejecución de las tareas, el examinador completaba una grilla de control, calificando las respuestas como válidas y no válidas siguiendo criterios de exclusión que se detallan más adelante. El intervalo entre tareas fue de dos minutos. La sesión completa de cada participante duró aproximadamente 30 minutos.

Análisis de datos conductuales

Para el análisis de las respuestas conductuales (precisión y RT) de los sujetos, se excluyeron aquellos ensayos que cumplían alguno de los siguientes criterios: (i) ausencia de respuesta; (ii) duda o comienzo fallido, por ejemplo, *fury*→*fueg*... *¡furia!*; (iii) confusión entre tareas, al traducir una palabra en lugar de leerla o viceversa; (iv) traducción incorrecta (por ejemplo, *fury*→*fuera*); (v) traducciones previamente no definidas (por ejemplo, *fury*→*ira*); (vi) RT con valores atípicos, es decir, mayores a 2000 ms o separados de la media en una cantidad mayor a 3 desvíos estándar (este último criterio de exclusión corresponde únicamente al análisis de RT, y no al de precisión). Con el conjunto de ensayos que superaron este proceso de exclusión, se implementó el mismo esquema de análisis estadístico tanto para los datos de RT como para los de precisión. Concretamente, se calculó el promedio de los valores de RT y precisión para cada sujeto y para cada condición por separado, para luego efectuar un análisis de varianza (ANOVA) de medidas repetidas de 2x2 utilizando el software JASP (versión 0.10.2.0) [29]. Los

factores del análisis fueron dos: el tipo de tarea (lectura o traducción) y el idioma del estímulo (L1 o L2). Los efectos de las interacciones entre factores principales fueron evaluados mediante análisis post-hoc de Holm.

Registro y preprocesamiento de EEG

Se registraron señales de EEG de cada participante durante la realización de las cuatro tareas del experimento. Se utilizó un sistema Biosemi Active-two de 128 canales con sensores preamplificados y un amplificador de acoplamiento de CC. Todas las señales fueron muestreadas originalmente a 1024 Hz, luego submuestreadas a 512 Hz, y referenciadas al promedio de los electrodos. Este es el valor considerado como potencial nulo, de modo que las diferencias de potencial registradas fueron medidas con respecto a esta referencia. A continuación, las señales de EEG fueron filtrados entre 0.5 y 45 Hz y se definieron épocas (intervalos de tiempo alrededor de cierto evento de interés) entre -0.5 segundos y 1 segundo respecto del tiempo de aparición del estímulo. A través de un análisis de componentes principales, se eliminaron los artefactos de las señales generados por movimientos oculares y pestañeos. Este método efectúa una transformación que descompone la señal de EEG en variables ortogonales entre sí que concentran las características más relevantes de la señal. De esta manera, es posible identificar y eliminar fuentes de ruido independientes de otras dimensiones en el espacio transformado. Por medio de una inspección visual, se eliminaron los artefactos remanentes y, además, se interpolaron canales ruidosos. El proceso de interpolación consiste en estimar la actividad en electrodos faltantes (en este caso, descartados por registros ruidosos) a partir de las señales registradas por otros electrodos cercanos. Las épocas correspondientes a respuestas incorrectas, inválidas o con valores atípicos de RT fueron removidas de las señales. Todas las etapas de procesamiento de las señales de EEG fueron implementadas en MATLAB (vR2016a) [30] utilizando el *toolbox* EEGLAB [31] (v14.1.2).

Oscilaciones

Para cuantificar el espectro de potencia de las señales registradas, se utilizó la Transformada Rápida de Fourier (FFT) con ventanas Hanning de 250 ms implementada en FieldTrip [32] para cada condición experimental. Siguiendo evidencia previa en tareas

de traducción de palabras [14, 33-36], la potencia espectral fue promediada en las bandas de frecuencia beta baja (14-20 Hz) y beta alta (21-30 Hz). Tales valores fueron normalizados con respecto a la actividad basal (300 ms previos a la aparición del estímulo) para corregir la disminución de potencia vinculada al aumento de frecuencias [6]. Por último, la potencia fue convertida a decibeles (dB), de modo que resultados negativos corresponden a procesos que evocan una menor potencia espectral comparada con la actividad basal (*desincronización*), mientras que valores positivos corresponden a un aumento de la potencia espectral en comparación con el período basal (*sincronización*).

Para obtener resultados con especificidad temporal, se calculó la potencia espectral en dos ventanas temporales contiguas: una ventana temporal temprana (0-300 ms), asociada con procesamiento temprano de tareas lingüísticas, y una ventana temporal tardía (300-600 ms), vinculada con diversos procesos léxico-semánticos [15, 37-39].

Una vez calculada la potencia espectral para cada condición y ventana temporal para las frecuencias de interés, se efectuaron comparaciones estadísticas entre los siguientes pares de condiciones:

1. Lectura en L2 (L2R) vs. Lectura en L1 (L1R), para estudiar las diferencias de lectura entre lenguas.
2. Traducción hacia adelante (FTR) vs. traducción hacia atrás (BTR), para estudiar las diferencias en la dirección de traducción entre idiomas.
3. La resta de traducción hacia adelante y lectura en L1 (FTR-L1R) vs. la resta de traducción hacia atrás y lectura en L2 (BTR-L2R), para estudiar las diferencias en la dirección de traducción entre idiomas cancelando efectos comunes vinculados al lenguaje en el que fue presentado el estímulo (L1 para FTR y L2 para BTR) y para eliminar la modulación inevitable de lectura presente en tareas de traducción.

Puesto que las señales de EEG se registran por gran cantidad de sensores y en muchos instantes de tiempo y/o frecuencias, la comparación estadística entre condiciones experimentales es, usualmente, evaluada en una enorme cantidad de ternas (electrodo, tiempo, frecuencia). Esto aumenta sensiblemente la probabilidad de cometer errores de tipo I; esto es, la probabilidad de concluir, erróneamente, que existe una diferencia significativa entre las condiciones experimentales, cuando tal efecto en realidad no está presente. Dicha tasa de errores de tipo I (conocida, en inglés, como *family-wise error*

rate) no puede controlarse por medio de técnicas estándar (como los métodos de Bonferroni o similares), sino que se vuelve necesario efectuar un análisis estadístico que tome en consideración la información global, contenida en todo el dominio de los datos, y no a nivel de puntos espacio-temporo-espectrales específicos. Por este motivo, se utilizó un enfoque no paramétrico [40] en las comparaciones estadísticas entre condiciones, que consta de los siguientes pasos:

1. Se reúnen los ensayos de las dos condiciones comparadas en un único conjunto.
2. Se eligen aleatoriamente, del conjunto completo, el número de ensayos correspondiente a la condición 1 y se asignan esos ensayos al subconjunto 1. Los ensayos remanentes conformarán el subconjunto 2. Este procedimiento se conoce como partición aleatoria.
3. Se realiza el cálculo de la prueba estadística para la partición obtenida.
4. Se repiten los pasos 2 y 3 un número suficientemente grande de veces (2000), y se construye un histograma de los valores del estadístico.
5. A partir del resultado del test estadístico de los datos efectivamente observados en el experimento y del histograma obtenido en el paso 4, se calcula la proporción de particiones aleatorias que hayan arrojado un resultado estadístico mayor que el que se obtuvo a partir de los datos observados (método de Monte Carlo). Esta proporción es el valor p de la comparación estadística.
6. Si el valor p es menor que el valor alfa crítico, se puede concluir que los datos de ambas condiciones experimentales son significativamente diferentes entre sí.

Cuando el número de particiones aleatorias tiende a infinito, el histograma construido en el paso 4 tiende a la distribución de probabilidad de la permutación. El valor p correspondiente a la comparación efectuada se denomina usualmente valor p de la permutación. En términos prácticos, es imposible calcular el valor p de la permutación repitiendo los pasos 2 y 3 una cantidad infinita de veces, por lo que se debe aproximar a partir de una estimación de Monte Carlo (paso 5). Cabe destacar que una de las principales ventajas del método utilizado es su naturaleza no paramétrica: este tipo de análisis estadístico no requiere que los datos cumplan con supuestos sobre sus distribuciones de probabilidad, a diferencia de los métodos paramétricos.

Así, en lugar de evaluar la diferencia entre condiciones experimentales para cada terna (electrodo, tiempo, frecuencia) individual, se la evalúa por medio de un único test estadístico que condense la información de todo el dominio espacio-temporo-espectral.

Los grupos de puntos (electrodo, tiempo, frecuencia) significativos, y que responden a algún criterio de cercanía, forman conjuntos llamados clústeres, y el estadístico utilizado por este método condensa la información estadística global de cada clúster así constituido (ver detalles más adelante). Al dividir el análisis en ventanas temporales específicas (temprana y tardía) y en bandas de frecuencia beta baja y beta alta, la dimensión utilizada para formar clústeres fue la espacial, basada en la topografía de los sensores de EEG. De esta manera, se determinó qué conjuntos de electrodos evidenciaban diferencias significativas entre condiciones experimentales, para cada combinación de ventana temporal y banda de frecuencia definidas. El método para el cálculo de clústeres espaciales que mostraron diferencias estadísticamente significativas entre condiciones experimentales puede resumirse en los siguientes pasos:

1. Se determina un valor umbral alfa crítico ($\alpha_{\text{elec}} = 0.01$), para identificar electrodos individuales que muestren diferencias significativas entre condiciones.
2. Los electrodos identificados en el paso 1 se agrupan en clústeres basados en un criterio de cercanía, que, en este caso, fue medida en términos de la distancia euclidiana entre electrodos adyacentes.
3. Para cada clúster así formado, se calcula la suma total del estadístico de todos los electrodos que lo conforman, es decir, el valor de una prueba t a dos colas para muestras dependientes. En adelante, se hará referencia a esta medida estadística a nivel de clústeres con la denominación de *ClusterStat*.
4. Se define como resultado estadístico global para la comparación entre condiciones el máximo (positivo) y mínimo (negativo) de los valores de *ClusterStat* obtenidos en 3.
5. Se realizan 2000 particiones aleatorias, en cada una de las cuales se repiten los pasos 1-4.
6. Para cada clúster identificado en la comparación original, se determina la proporción de permutaciones que generaron un resultado estadístico más extremo que el valor de *ClusterStat* correspondiente. Dicha proporción es el valor p_{clus} del clúster respectivo.
7. Se determina un segundo valor crítico α_{CV} . Para cada clúster en la muestra observada, se compara el valor p_{clus} obtenido en 6 con α_{CV} . Si es menor, se considera dicho clúster como significativo.

La lógica detrás del proceso de decisión estadística del paso 7 es la siguiente:

$$P(\text{al menos un valor de } |ClusterStat| \geq CV) = \alpha_{CV}, \quad [3]$$

o, equivalentemente,

$$P(\text{Máx}(|ClusterStat|) \geq CV) = \alpha_{CV}, \quad [4]$$

siendo CV el valor de $ClusterStat$ asociado a α_{CV} .

Se efectuó un análisis estadístico a dos colas, con $\alpha_{CV} = 0.01$.

Correlaciones entre RT y patrones oscilatorios

Con el objetivo de estudiar la asociación entre los resultados significativos del análisis de frecuencias con aspectos conductuales, se calcularon correlaciones de Pearson entre los RT y la potencia espectral promedio de cada clúster significativo.

Para cada uno de los clústeres que mostraron diferencias significativas entre condiciones, y para cada uno de los 14 sujetos que participaron del estudio, se procedió de la siguiente manera:

1. Se calculó la potencia espectral promedio de todos los electrodos que conforman el clúster en cuestión, para las dos condiciones por separado.
2. Se promediaron los valores de tiempos de reacción sobre todos los ensayos, para cada condición por separado.
3. Se analizaron las correlaciones Pearson para cada conjunto de puntos así definidos. Dichas correlaciones fueron consideradas significativas si su valor p era menor a 0.05.

Conectividad

Para cuantificar la conectividad funcional durante las tareas experimentales, se utilizó una medida de conectividad funcional denominada información simbólica mutua ponderada ($wSMI$, *weighted Symbolic Mutual Information*) [18], una medida utilizada previamente en diversos estudios de EEG [18-22].

El concepto de información mutua es un enfoque simple pero robusto que permite cuantificar la cantidad de información compartida entre dos variables. Se trata de una

métrica de entropía, que es una medida de incertidumbre: valores altos de entropía indican que el sistema bajo estudio puede tomar una mayor variedad de estados o configuraciones. En términos prácticos, la información mutua es una medida de la cantidad de información compartida por dos variables, y puede calcularse sumando las entropías individuales de ambas variables y luego sustrayendo su entropía conjunta. Cuando ambas señales presentan oscilaciones conjuntas no aleatorias, se concluye que comparten estados similares durante cierto período de tiempo, y, por tanto, que existe un intercambio de información entre ellas.

Frente a otros métodos de análisis de conectividad utilizados en neurociencias, se eligió este en particular porque presenta tres ventajas principales. En primer lugar, busca patrones cualitativos o “simbólicos” de incremento o de decremento en los valores de la señal, lo que posibilita la estimación rápida y robusta de las entropías de las señales. En segundo lugar, wSMI impone pocas hipótesis respecto al tipo de interacciones esperadas y permite detectar acoplamiento no lineal. Por último, la asignación de pesos particulares a pares de electrodos específicos durante el cálculo de wSMI hace posible descartar correlaciones espurias entre señales de EEG que surjan de fuentes comunes, mientras que favorece la formación de pares de símbolos no triviales. Este factor es crucial, ya que se sabe que la EEG es sensible a una serie de artefactos, como la contracción muscular, pestañeos y conducción volumétrica, que pueden incrementar de forma espuria la similitud entre patrones de EEG registrados por dos sensores distintos. En particular, se aplican pesos que benefician aquellos pares de símbolos con poca probabilidad de ser generados por una fuente común y, contrariamente, se atribuye un peso nulo a los pares de símbolos que es probable que se originen por artefactos de fuente común. Concretamente, los casos triviales corresponden a la formación de pares idénticos ($S_X = S_Y$) y pares exactamente opuestos ($S_X = -S_Y$). Este último caso puede presentarse si dos electrodos de EEG registran señales a cada lado de un mismo dipolo eléctrico, algo muy común en la medición de señales de EEG.

En primer lugar, para obtener los coeficientes de wSMI, se transforman las señales X , Y registradas por dos electrodos en secuencias de símbolos discretos; luego, se calcula la entropía de cada señal transformada (\hat{X} , \hat{Y}). Dicha transformación se realiza extrayendo subvectores de la señal original, cada uno de los cuales está formado por k puntos separados entre sí por τ ms. Para un k dado, existen $k!$ ordenamientos posibles y, por ende, $k!$ símbolos distintos. Se fijó el valor de k en 3 (correspondiente a una cantidad total de 6

símbolos distintos) para estimar de forma robusta las densidades de probabilidad de las señales transformadas. Un valor de $k = 4$ implicaría la existencia de 24 símbolos posibles, y, por lo tanto, $24^2 = 576$ combinaciones para dos señales. En tal caso, se necesitarían señales mucho más extensas en tiempo para estimar de forma robusta los valores de wSMI (ver Datos Suplementarios de [18]). Puesto que el valor de τ define la separación temporal entre los k elementos que forman cada símbolo, también determina el rango de frecuencias para el cual esta medida resulta sensible. Aquí se considera el valor de $\tau = 16$ ms, puesto que ya fue reportado en estudios previos del campo de las neurociencias cognitivas [41]. En relación con la frecuencia de muestreo de las señales de EEG utilizadas en este trabajo, el valor de τ elegido para este análisis resulta sensible a frecuencias por debajo de 10 Hz, aproximadamente (para más detalles sobre la correspondencia entre τ y rangos de frecuencia, ver los Datos Suplementarios de [18]).

La información simbólica mutua se define como:

$$SMI(\hat{X}, \hat{Y}) = \frac{1}{\log(k!)} \sum_{\hat{x}} \sum_{\hat{y}} p(\hat{x}, \hat{y}) \log \left(\frac{p(\hat{x}, \hat{y})}{p(\hat{x})p(\hat{y})} \right). \quad [5]$$

donde \hat{x}, \hat{y} son los símbolos presentes en las señales \hat{X}, \hat{Y} , respectivamente, $p(\hat{x}, \hat{y})$ es la probabilidad de ocurrencia simultánea de los símbolos \hat{x} en \hat{X} y \hat{y} en \hat{Y} , $p(\hat{x})$ y $p(\hat{y})$ son las probabilidades de cada símbolo en la señal correspondiente (todas ellas estimadas a partir de histogramas obtenidos para las señales transformadas) y $k!$ es el número de símbolos posibles (usado para normalizar el resultado respecto a la entropía máxima de las señales). El cómputo de wSMI es muy similar al de SMI, con la inclusión del factor adicional de ponderación w :

$$wSMI(\hat{X}, \hat{Y}) = \frac{1}{\log(k!)} \sum_{\hat{x}} \sum_{\hat{y}} w(\hat{x}, \hat{y}) p(\hat{x}, \hat{y}) \log \left(\frac{p(\hat{x}, \hat{y})}{p(\hat{x})p(\hat{y})} \right), \quad [6]$$

con $0 \leq w(\hat{x}, \hat{y}) \leq 1$, correspondiendo el valor 0 a los pares de símbolos triviales (ver Datos Suplementarios de [18]).

Para cada condición experimental y para cada uno de los ensayos correspondientes, se calcularon los patrones de conectividad entre las señales registradas por cada uno de los 128 electrodos utilizados. En total, para cada ensayo se obtuvieron $\frac{128 \times 127}{2} = 8128$ valores de wSMI, que fueron posteriormente dispuestos en matrices de 128 filas y 128 columnas. La división por 2 obedece a que esta medida de conectividad no toma en cuenta la dirección de la interacción: es decir, la interacción entre los

electrodos (i,j) es exactamente la misma que la interacción entre los electrodos (j,i) . Cada entrada (i,j) de tales matrices representa el valor de wSMI que cuantifica el grado de conectividad entre los electrodos $i, j = 1, 2, \dots, 128$.

Para rodear el problema de comparaciones múltiples también presente en el análisis estadístico de los resultados de wSMI, se optó por un enfoque de clústeres similar al utilizado para el análisis de frecuencias. El procedimiento puede resumirse en los siguientes pasos:

1. Se calculan las matrices de conectividad para cada condición.
2. Se define un valor α crítico para identificar conexiones estadísticamente significativas ($\alpha_{\text{con}} = 0.01$).
3. Se agrupan aquellas conexiones que involucren electrodos vecinos, según el criterio de vecindad basada en la distancia euclidiana entre sensores adyacentes. Dos conexiones se consideran vecinas si al menos uno de los electrodos de una de ellas es vecino de al menos uno de los electrodos de la otra. En términos prácticos, una conexión $(el1, el2)$ es vecina de otra $(el3, el4)$ si $el1$ es un electrodo vecino de $el3$ y/o $el4$, o si $el2$ lo es.
4. Para cada clúster así formado, se calcula la suma total del estadístico de todas las conexiones que lo conforman, es decir, el valor de una prueba t a dos colas para muestras dependientes. En adelante, se hará referencia a esta medida estadística a nivel de clústeres con la denominación de *ClusterStat*.
5. Se define como resultado estadístico global para la comparación entre condiciones el máximo (positivo) y mínimo (negativo) de los valores de *ClusterStat* obtenidos en 4.
6. Se realizan 2000 particiones aleatorias de las matrices de conectividad, en cada una de las cuales se repiten los pasos 2-5.
7. Para cada clúster identificado en la comparación original, se determina la proporción de permutaciones que generaron un resultado estadístico más extremo que el valor de *ClusterStat* correspondiente. Dicha proporción es el valor p_{clus} del clúster respectivo.
8. Se determina un segundo valor crítico α_{CV} . Para cada clúster en la muestra observada se compara el valor p_{clus} obtenido en 7 con α_{CV} . Si es menor, se considera dicho clúster como significativo.

Se efectuó un análisis estadístico a dos colas, con $\alpha_{CV} = 0.05$.

Se repitió este análisis estadístico para las dos ventanas temporales definidas en el análisis de frecuencias (ventana temprana: 0-300 ms y ventana tardía: 300-600 ms) y $\tau = 16$ ms. Se efectuaron comparaciones estadísticas entre los mismos pares de condiciones experimentales expuestos en el análisis de frecuencias (es decir, L2R vs. L1R, FTR vs. BTR y FTR-L1R vs. BTR-L2R). Se incluyeron únicamente el 10% de conexiones más extremas (en términos de los valores t correspondientes) para visualizar la topografía de los resultados más significativos.

Métodos de aprendizaje estadístico

Para determinar si los resultados obtenidos de los análisis de frecuencias y de conectividad permitían clasificar el tipo de actividad generada en respuesta a las condiciones experimentales consideradas, se entrenaron cuatro clasificadores definiendo predictores vinculados con los resultados derivados de los análisis respectivos para L2R vs. L1R, FTR vs. BTR y FTR-L1R vs. BTR-L2R.

Los clasificadores considerados en este estudio fueron los siguientes:

- Análisis de Discriminante Lineal (en inglés, *Linear Discriminant Analysis*).
- Análisis de Discriminante Cuadrático (en inglés, *Quadratic Discriminant Analysis*).
- Clasificador de Vectores de Soporte Lineal (en inglés, *Linear Support Vector Classifier*).
- Clasificador de K Vecinos Más Cercanos (en inglés, *K-Nearest Neighbors Classifier*).

Para cada clasificador se realizó una validación cruzada de 10 pasos. Los clasificadores fueron implementados en Python 3.8 [42] con el uso de la librería Scikit-learn [43] (versión 0.24.1).

Predictores (*features*) considerados

En lo que respecta a la clasificación basada en los resultados de los análisis de frecuencia y de conectividad, se utilizaron como predictores los valores medios de la

potencia espectral y de wSMI de cada clúster significativo para cada sujeto y para cada ensayo individual, en ambas condiciones experimentales.

Las máscaras utilizadas para definir electrodos significativos (en el análisis de frecuencias) o conexiones significativas (en el análisis de conectividad) fueron aquellas provistas por los correspondientes análisis estadísticos para registrar diferencias significativas entre condiciones experimentales.

Análisis de Discriminante Lineal

El estimador \hat{G} que genera el mínimo error de clasificación posible (estimador óptimo) se denomina estimador bayesiano, y se obtiene al asignar a cada entrada x la clase g que maximice la probabilidad condicional:

$$P(G = g|X = x). \quad [7]$$

Es decir,

$$\hat{G}(x) = g \text{ si } P(G = g|X = x) = \max_k (P(G = k|X = x)). \quad [8]$$

En la práctica no es posible contar con la información sobre la distribución de probabilidad $P(G|X)$, por lo que es necesario estimarla [25].

Con este objetivo, se designa con $f_k(x)$ a la función de densidad de probabilidad de la entrada X condicionada a la clase k ($f_k(x) = P(X = x|G = k)$, es decir, la probabilidad de obtener una observación $X = x$, sabiendo que pertenece a la clase k) y con $\pi_k = P(G = k)$, a la probabilidad, *a priori*, de que una observación cualquiera pertenezca a la clase k . Si se asumen conocidas estas dos distribuciones, es posible estimar la probabilidad condicional $P(G = g|X = x)$ haciendo uso del Teorema de Bayes. En este contexto, el teorema establece que la probabilidad de que una observación x pertenezca a la clase k ($P(G = g|X = x)$) es proporcional al producto entre la probabilidad condicional $f_k(x)$ (denominada verosimilitud, o *likelihood*, en inglés) y la probabilidad *a priori* π_k asociada a la clase k :

$$P(G = g|X = x) = \frac{P(X=x|G=k)P(G=k)}{P(X=x)} = \frac{f_k(x)\pi_k}{\sum_{l=1}^K f_l(x)\pi_l}. \quad [9]$$

siendo K el número total de clases existentes.

El método de análisis de discriminante se basa en la ecuación [9], pero impone condiciones sobre las probabilidades intervinientes. En particular, las distribuciones de probabilidad condicionales $f_k(x)$ se modelan como distribuciones Gaussianas multivariadas:

$$f_k(x) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma_k|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \right), \quad [10]$$

siendo $x \in R^p$ el vector de entrada, $\mu_k \in R^p$ el valor medio de la clase k , $\Sigma_k \in R^{p \times p}$ la matriz de covarianza asociada a la clase k y $|\Sigma_k|$, su determinante. Adicionalmente, las matrices de covarianza de todas las clases deben ser iguales entre sí. Es decir,

$$\Sigma_k = \Sigma, \forall k=1, \dots, K. \quad [11]$$

Puesto que en la ecuación [9] el denominador es común a todas las clases consideradas, a la hora de comparar las probabilidades *a posteriori* $P(G = k|X = x), P(G = l|X = x)$, es suficiente analizar los numeradores. Si solo se consideran dos clases posibles (k, l), este método asigna una observación x a la clase k si $P(G = k|X = x) > P(G = l|X = x)$, y a la clase l en caso contrario. El límite de clasificación (frontera de decisión) se alcanza cuando ambas clases son igualmente probables, o, lo que es lo mismo,

$$\frac{P(G=k|X=x)}{P(G=l|X=x)} = 1. \quad [12]$$

Tomando el logaritmo natural de la ecuación [12] y reemplazando a las probabilidades *a posteriori* por las expresiones que surgen de la ecuación [9], se obtiene la siguiente equivalencia:

$$\ln \left(\frac{P(G=k|X=x)}{P(G=l|X=x)} \right) = \ln \left(\frac{f_k(x)}{f_l(x)} \right) + \ln \left(\frac{\pi_k}{\pi_l} \right) = 0. \quad [13]$$

Luego, utilizando la ecuación [10], se obtiene la siguiente expresión que permite obtener las fronteras de decisión de este método de análisis aplicado a la separación de dos clases:

$$\ln \left(\frac{f_k(x)}{f_l(x)} \right) + \ln \left(\frac{\pi_k}{\pi_l} \right) = \ln \left(\frac{\pi_k}{\pi_l} \right) - \frac{1}{2} (\mu_k + \mu_l)^T \Sigma^{-1} (\mu_k - \mu_l) + x^T \Sigma^{-1} (\mu_k - \mu_l) = 0. \quad [14]$$

Al extender este razonamiento a un conjunto de K clases $\{1, 2, \dots, K\}$, se obtiene, para cada clase k , una relación lineal en x , conocida como discriminante de la clase correspondiente:

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln(\pi_k), k = 1, 2, \dots, K \quad [15]$$

La frontera de decisión entre cada par de clases k, l se define como el conjunto de valores $\{x: \delta_k(x) = \delta_l(x)\}$.

Los parámetros de las distribuciones normales son estimados a partir del siguiente conjunto de ecuaciones:

$$\bullet \hat{\pi}_k = \frac{N_k}{N}, \quad [16]$$

siendo N_k el número de observaciones pertenecientes a la clase k -ésima.

$$\bullet \hat{\mu}_k = \frac{1}{N_k} \sum_{g_i=k} x_i. \quad [17]$$

$$\bullet \hat{\Sigma} = \frac{1}{N-K} \sum_{k=1}^K \sum_{g_i=k} (x_i - \hat{\mu}_k)^T (x_i - \hat{\mu}_k). \quad [18]$$

Análisis de Discriminante Cuadrático

Este método, a diferencia del análisis de discriminante lineal, que asume que las distribuciones normales de todas las clases comparten una misma matriz de covarianza, considera la posibilidad de que cada clase tenga su propia matriz de covarianza Σ_k . De este modo, se obtienen funciones discriminantes cuadráticas en términos de x :

$$\delta_k(x) = -\frac{1}{2} \ln|\hat{\Sigma}_k| - \frac{1}{2} (x - \hat{\mu}_k)^T \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) + \ln(\hat{\pi}_k), \quad [19]$$

con $\hat{\Sigma}_k = \frac{1}{N-1} \sum_{g_i=k} (x_i - \hat{\mu}_k)^T (x_i - \hat{\mu}_k)$. Nuevamente, las fronteras de decisión representan los puntos en el espacio p -dimensional $\{x: \delta_k(x) = \delta_l(x)\}$ [25].

Clasificación por K vecinos más cercanos

A diferencia de los análisis de discriminante lineal y cuadrático, la clasificación por vecinos más cercanos no ajusta ningún modelo a los datos [25]. Esto disminuye el sesgo (conjunto de suposiciones) del modelo, pero aumenta el riesgo de incurrir en un sobreajuste del conjunto de entrenamiento. Dado un vector de entrada x_0 , se buscan los k puntos del conjunto de entrenamiento $x_{(r)}, r = 1, 2, \dots, k$ que estén más cerca de x_0 según algún criterio utilizado para definir distancia entre los vectores $x \in R^p$. Normalmente, como medida de distancia, se utiliza la norma euclidiana de la diferencia entre dos puntos:

$$d_{(r)} = ||x_r - x_0||. \quad [20]$$

Se definió un valor del parámetro k aproximadamente igual a la décima parte del conjunto total de ensayos correspondientes a cada condición. Esta elección tuvo por objetivo generar una frontera de decisión aproximadamente lineal, que es más fácilmente interpretable [41] y evitar el problema de sobreajuste (*overfitting*).

Clasificador de vectores de soporte lineal

Dado un conjunto de entrenamiento de N puntos $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$, con $x_i \in R^p, y \in \{-1; 1\}$, se define un hiperplano en el espacio p -dimensional a partir de la relación lineal entre los vectores x_i :

$$\{x: f(x) = x^T \beta + \beta_0\}, \quad [21]$$

$$\beta \in R^p, \beta_0 \in R. \quad [22]$$

Éste divide el espacio p -dimensional en dos, asignando las nuevas observaciones a las clases $+1$ o -1 dependiendo del lado del hiperplano donde se encuentre la nueva observación x . Si $f(x) > 0$, se le asigna a x la clase $+1$, mientras que, si $f(x) < 0$, se le asigna la clase -1 . Así, el criterio de clasificación es

$$G(x) = \text{signo}[x^T \beta + \beta_0]. \quad [23]$$

Cuanto mayor es el valor absoluto de $f(x)$, mayor es la confianza en la clasificación. Si $x^T \beta + \beta_0 \gg 0$ es posible asegurar con mayor certeza que la observación x pertenece a la clase $+1$. A su vez, si $x^T \beta + \beta_0 \ll 0$, mayor es la certeza que se tendrá en asignar el punto x a la clase -1 . Nótese, además, que $y_i(x_i^T \beta + \beta_0) > 0$ para todos los puntos que conforman el conjunto de entrenamiento [25].

Para un conjunto de puntos linealmente separables, existen infinitos hiperplanos que separan ambas clases. Aquel hiperplano cuya distancia a los puntos del conjunto de entrenamiento (el margen del clasificador, M) sea máxima será el que brinde resultados más confiables, es decir:

$$\max_{\beta, \beta_0} M, \quad [24]$$

$$\text{sujeto a la condición } y_i(x_i^T \beta + \beta_0) \geq M, i = 1, 2, \dots, N. \quad [25]$$

El valor de M se define como la distancia entre el hiperplano y el punto del espacio p -dimensional más cercano a él, que recibe el nombre de vector de soporte. Los parámetros del hiperplano dependen exclusivamente de los vectores de soporte que lo definen, por lo que este método tiene la ventaja de ser menos sensible a valores atípicos en los vectores de entrada (denominados *outliers*).

En caso de que las dos clases no sean linealmente separables, ningún hiperplano será capaz de separar todos los elementos del conjunto de entrenamiento. Para extender este análisis al caso de clases no linealmente separables, se permite que algunos puntos queden del lado equivocado del margen del hiperplano, de modo que ciertas observaciones se encuentran más cerca del hiperplano que los vectores de soporte utilizados para definirlo, o, incluso, que sean erróneamente clasificados (asignados a la clase +1 cuando, en realidad, pertenecen a la clase -1, o viceversa). Para eso, se introduce un nuevo parámetro $\xi = (\xi_1, \xi_2, \dots, \xi_N)$, que define cuán tolerante es el método a errores de clasificación. Si $0 < \xi_i < 1$, se permite que el punto x_i quede ubicado dentro del margen del clasificador, pero del lado correcto del hiperplano. Si $\xi_i > 1$, el punto x_i puede quedar del lado incorrecto del hiperplano. La condición de maximización se convierte en

$$\max_{\beta, \beta_0} M, \quad [26]$$

sujeto a la condición

$$y_i(x_i^T \beta + \beta_0) \geq M(1 - \xi_i), \forall i, \xi_i \geq 0, \sum_{i=1}^N \xi_i \leq C \quad [27]$$

para alguna constante C que representa el número máximo de puntos que pueden quedar en el lado equivocado del margen (o del hiperplano). En este caso, se utilizó $C = 1$. Esta decisión obedece a varios factores: (i) el conjunto de entrenamiento no era lo suficientemente grande como para hallar el valor de C óptimo partiendo los datos en tres conjuntos para ajustar este hiperparámetro y (ii) este mismo valor de C fue utilizado en estudios neurocientíficos previos que justifican su uso [41, 44] y (iii) es el valor recomendado de la librería Scikit-Learn [43].

Resultados

Análisis conductuales

Precisión

El análisis de precisión mostró un efecto principal asociado al tipo de tarea ($F(1,55) = 40.002$; $p < 0.001$; η parcial = 0.755) y al lenguaje del estímulo ($F(1,55) = 8.680$; $p = 0.011$; η parcial = 0.400). Los análisis post-hoc revelan mayor grado de precisión para lectura frente a traducción (diferencia media: 0.091; $t = 6.325$; $p < 0.001$), y lo mismo vale para estímulos presentados en L1 frente a aquellos presentados en L2 (diferencia media: 0.013; $t = 2.946$; $p = 0.011$). No se encontraron efectos asociados a las interacciones entre ninguno de los factores involucrados en el análisis.

Tiempos de reacción

Se observó un efecto principal asociado al tipo de tarea ($F(1,55) = 112.671$; $p < 0.001$; η parcial = 0.897). El análisis post-hoc reveló que las tareas de lectura fueron significativamente más rápidas que las tareas de traducción (diferencia media: -226.483 ms; $t = -10.615$; $p < 0.001$). No se registraron efectos principales asociados al lenguaje del estímulo. Además, se observó una interacción significativa entre tarea y lenguaje del estímulo ($F(3,55) = 15.426$; $p = 0.002$; η parcial = 0.543). Según el análisis post-hoc, la lectura en L1 muestra tiempos de reacción menores que la lectura en L2 (diferencia media: -56.769 ms; $t = -3.530$; $p_{\text{holm}} = 0.003$). La comparación entre BTR y FTR mostró diferencias significativas, siendo la traducción hacia atrás más rápida que la traducción hacia adelante (diferencia media: -40.201 ms; $t = -2.500$; $p_{\text{holm}} = 0.019$).

Oscilaciones

Los análisis de frecuencias lograron capturar un efecto significativo (permutaciones: $p_{\text{elec}} < 0.01$; $p_{\text{clus}} < 0.01$) de asimetría en las direcciones de traducción, es decir, entre las respuestas evocadas en FTR y BTR. Particularmente, se observaron diferencias significativas en ventana tardía (300-600 ms) para las bandas beta baja (14-

20 Hz) y beta alta (21-30 Hz) (ver Figura 3), pero ninguna diferencia entre las tareas de lectura (L2R vs. L1R) ni para las tareas de traducción con el efecto de lectura sustraído (FTR-L1R vs. BTR-L2R).




Figura 3. Diferencia significativa (permutaciones; $p_{elec} < 0.01$; $p_{clus} < 0.01$) entre las condiciones FTR y BTR para ventana temporal tardía (300-600 ms) y (A) banda de frecuencia beta baja (14-20 Hz) (B) banda de frecuencia beta alta (21-30 Hz). En ambos casos se aprecian patrones de desincronización respecto de la actividad basal, siendo mayor el grado de desincronización durante el proceso de traducción hacia adelante (FTR).

Correlación entre tiempos de reacción y potencia espectral

El análisis mostró una correlación de Pearson significativa ($p < 0.05$) para BTR. Particularmente, se evidencia una correlación positiva entre RT y potencia espectral del clúster frontal obtenido para la ventana tardía (300-600 ms) y banda beta baja (14-20 Hz) ($\rho = 0.5350$, $p < 0.05$) (ver Figura 4).




Figura 4. Correlación de Pearson significativa ($p < 0.05$) entre RT y potencia media del clúster frontal observado en la ventana tardía (300-600 ms) y banda beta baja (14-20 Hz) para BTR.

Conectividad

Se hallaron diferencias significativas (permutaciones: $p_{con} < 0.01$; $p_{clus} < 0.05$) para la ventana tardía (300-600 ms), $\tau = 16$ ms (< 10 Hz) en la comparación FTR-L1R vs. BTR-L2R (ver Figura 5).

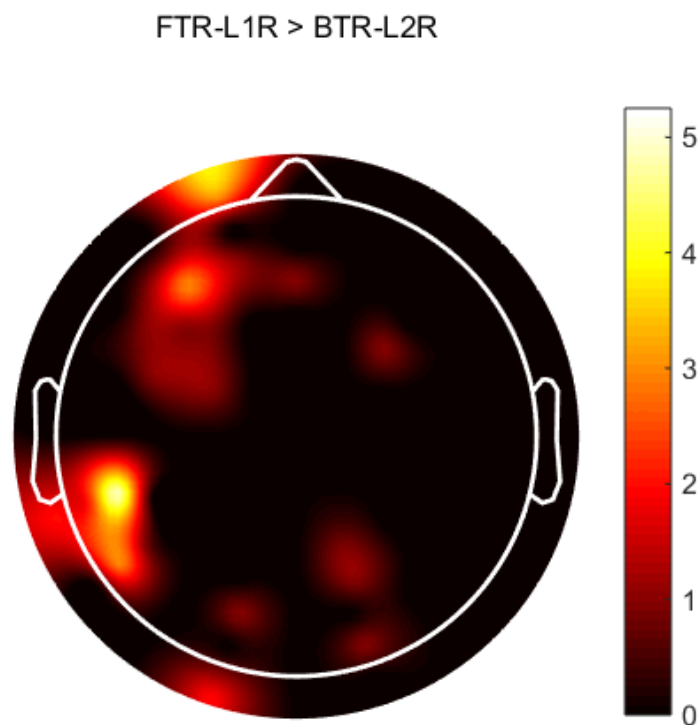


Figura 5. Número de conexiones estadísticamente significativas (permutaciones: $p_{con} < 0.01$; $p_{clus} < 0.05$) en las que participan los electrodos incluidos en el clúster correspondiente a la comparación entre FTR-L1R y BTR-L2R ($\tau=16$ ms., ventana temporal tardía: 300-600 ms.). Todas las conexiones indicadas presentaron patrones de conectividad más intensos (mayores valores de wSMI) en FTR-L1R que en BTR-L2R. La barra lateral indica la cantidad de conexiones de las que participa cada uno de los electrodos que aparecen representados. Todos ellos corresponden a un único clúster de conexiones significativas. Se incluyen solo aquellas conexiones con valores t dentro del 10% más extremo, en términos absolutos.

Los patrones de conectividad demuestran ser más intensos (valores mayores de wSMI) para la condición FTR-L1R. Las diferencias observadas en las comparaciones entre direcciones de traducción involucran regiones frontales ligeramente lateralizadas hacia la izquierda y temporo-parietales izquierdas.

De manera similar a lo observado en la comparación entre tareas de traducción con lectura sustraída, el análisis propuesto logró capturar diferencias significativas (permutaciones: $p_{con} < 0.01$; $p_{clus} < 0.05$), en ventana tardía (300-600 ms) para $\tau = 16$ ms (< 10.33 Hz) correspondientes a la comparación L2R vs. L1R (ver Figura 6).

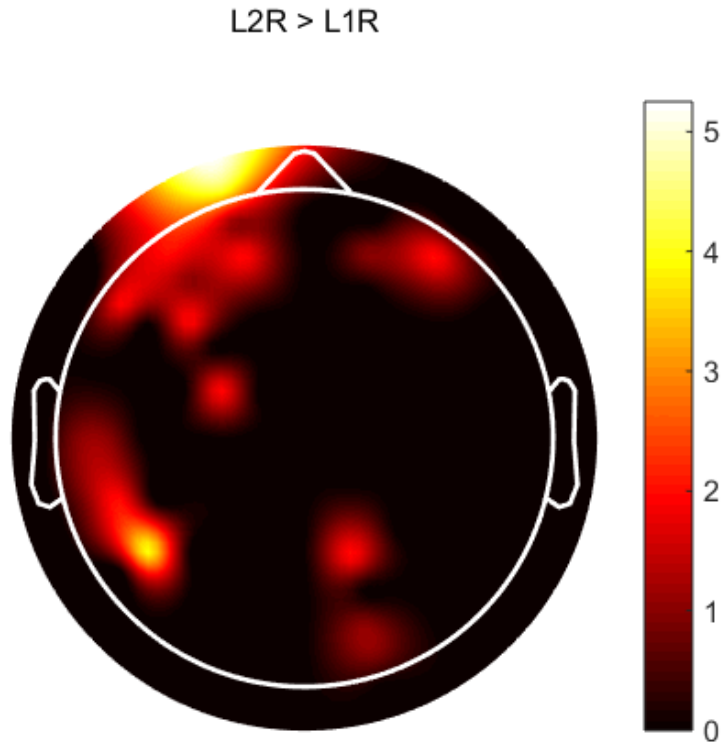


Figura 6. Número de conexiones estadísticamente significativas (permutaciones: $p_{con} < 0.01$; $p_{clus} < 0.05$) de las que participan los electrodos incluidos en el clúster correspondiente a la comparación entre L2R y L1R ($\tau=16$ ms., ventana temporal tardía: 300-600 ms.). Todas las conexiones indicadas implican patrones de conectividad más intensos (mayores valores de wSMI) en L2R que en L1R. Se incluyen solo aquellas conexiones con valores t dentro del 10% más extremo, en términos absolutos.

Los patrones de conectividad demuestran ser más intensos (mayores valores de wSMI) para L2R. Al igual que lo observado en la comparación entre direcciones de traducción, pueden identificarse dos patrones topográficos bien marcados: uno de ellos en la región frontal, ligeramente lateralizado hacia la izquierda y otro en la región temporo-parietal izquierda.

No se observaron diferencias significativas para comparación entre direcciones de traducción (FTR vs. BTR).

Métodos de aprendizaje estadístico

Ninguno de los clasificadores implementados presentó un desempeño de clasificación significativamente superior al azar ($AUC = 0.5$). A modo de ejemplo, a continuación, se muestra el resultado correspondiente a la clasificación de tareas de

traducción (FTR vs. BTR) basado en los datos de potencia espectral correspondientes a los clústeres observados en las bandas beta baja (14-20 Hz) y beta alta (21-30 Hz) en ventana temporal tardía (300-600 ms) (ver Figura 7). Los resultados obtenidos sobre la clasificación entre L2R y L1R basada en los resultados de conectividad pueden verse en el Apéndice.

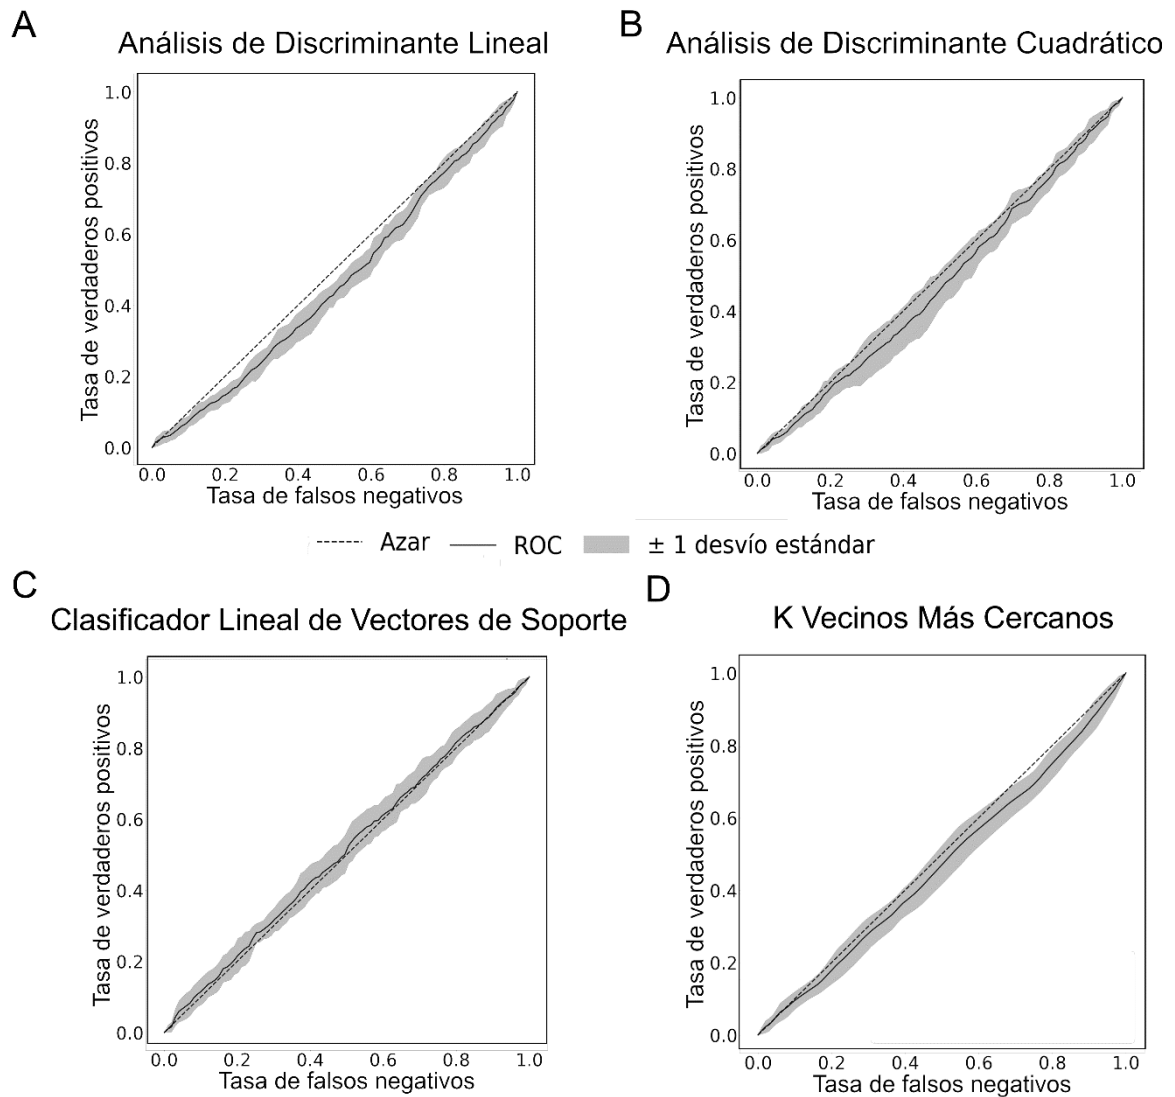


Figura 7. Clasificación entre FTR y BTR basada en la potencia espectral media de los clústeres significativos correspondientes a la banda beta baja (14-20 Hz) y beta alta (21-30 Hz). Se consideraron ambos valores como predictores (*features*) independientes. Se muestran las curvas ROC medias de cada clasificador a lo largo de los 10 pasos de validación cruzada implementados, junto con el desvío estándar correspondiente. En línea punteada se destaca la curva ROC de un clasificador por azar ($AUC = 0.5$) (A) Análisis de Discriminante Lineal ($AUC = 0.457 \pm 0.019$); (B) Análisis de Discriminante Cuadrático ($AUC = 0.474 \pm 0.031$); (C) Clasificador Lineal de

Vectores de Soporte ($AUC = 0.468 \pm 0.027$); (D) K Vecinos Más Cercanos ($K = 132$) ($AUC = 0.472 \pm 0.029$).

Discusión

El objetivo del presente trabajo fue identificar marcadores neurocognitivos que explicaran las diferencias observadas en los procesos de lectura y traducción, con particular énfasis en el efecto de asimetría en las direcciones de traducción, que ha sido escasamente explorado hasta el momento, y menos aún mediante el uso de las herramientas aquí presentadas. De hecho, este aspecto del procesamiento bilingüe prácticamente no ha recibido atención de parte de la literatura especializada en el tema, que consideró tradicionalmente a la traducción hacia atrás como la única dirección relevante, tal vez como consecuencia de un fuerte sesgo angloparlante [8]. No obstante, las tareas de FTR deben realizarse más frecuentemente que las tareas de BTR en países no angloparlantes. La principal evidencia científica en lo que hace a este aspecto del procesamiento bilingüe proviene, esencialmente, de análisis conductuales (precisión y RT) [45-47], imágenes funcionales [48-50], potenciales evocados [51, 52] y un número muy limitado de estudios que involucran medidas de conectividad funcional a partir de señales de EEG o electroencefalografía intracraneal (iEEG) [7]. En este sentido, los resultados obtenidos en este estudio son novedosos, puesto que abordan la temática desde una perspectiva antes no explorada.

En la comparación de tareas de lectura, y en términos del análisis de RT, los resultados son consistentes con estudios conductuales previos [46], que evidencian respuestas más rápidas en tareas de lectura en L1 frente a lectura en L2. Estos resultados muestran que la lectura en lengua materna, por estar asociada con respuestas más rápidas, demuestra ser más sencilla que la lectura en un lenguaje adquirido. Un análisis similar puede hacerse en relación con la comparación entre direcciones de traducción. La diferencia de RT también reproduce resultados previos [45-47] y puede interpretarse en el mismo sentido que el aplicado a la comparación entre tareas de lectura: existe un efecto conductual de asimetría en las direcciones de traducción, que refleja un esfuerzo cognitivo más importante (esto es, respuestas más lentas) para FTR frente a BTR, en línea con modelos canónicos del campo del bilingüismo. Concretamente, el modelo jerárquico revisado propuesto por Kroll y Stewart [53], establece que las conexiones neurales que

vinculan el procesamiento de información en L1 y en L2 en la dirección inversa (es decir, de L2 a L1) son más robustas que las que conectan a L1 con L2 en la dirección directa (esto es, de L1 a L2). Esto está basado en evidencia que indica que cuando una persona aprende una L2 después de haber consolidado su L1, se apoya en esta última durante el proceso de aprendizaje de la nueva lengua. Esto favorece el fortalecimiento de las conexiones que llevan información desde L2 hasta L1, pero no al revés.

Por otro lado, el fenómeno de asimetría en la dirección de traducción se observó, también, en los resultados frecuenciales. En particular, la modulación tardía de la banda beta (13-30 Hz), presentó un mayor grado de desincronización para FTR en comparación con BTR (permutaciones: $p_{elec} < 0.01$; $p_{clus} < 0.01$). Estos resultados en frecuencia son consistentes a la hora de asignar, sistemáticamente, un mayor grado de desincronización tardía en la banda beta a la tarea que evidencia tiempos de reacción más largos y que, por tanto, requiere un esfuerzo cognitivo mayor, tal como se sugirió en la discusión de los resultados de los análisis conductuales.

En el campo de la neurolingüística, múltiples estudios han caracterizados el rol de las oscilaciones en la banda beta. En el procesamiento lingüístico, Bastiaansen et al. [33] reportaron un mayor grado de desincronización en la misma banda de frecuencia asociado al procesamiento de palabras de clase abierta (como sustantivos, adjetivos y verbos) en comparación con el de palabras cerradas (como preposiciones, determinantes y conjunciones), principalmente en regiones occipitales. En el contexto específico del procesamiento bilingüe, Grabner et al. [15] observaron un efecto de desincronización en esta banda de frecuencia y en una ventana temporal tardía (400-700 ms posterior a la presentación del estímulo) para la traducción hacia atrás (BTR) de palabras, comparando aquellas con alta frecuencia de aparición en el corpus correspondiente, frente a las de menor frecuencia. Las diferencias observadas en esta banda de frecuencia indican una mayor desincronización para la traducción exitosa de palabras de alta frecuencia, en comparación con la traducción exitosa de palabras de baja frecuencia. Por otro lado, las palabras de baja frecuencia no traducidas evidenciaron un patrón de desincronización más intenso que las otras dos condiciones experimentales. Estos resultados muestran, en generales, un patrón de desincronización en la banda beta que resulta ser más intenso (mayores valores de wSMI) en tareas cognitivamente más exigentes, con excepción de la comparación efectuada entre la traducción exitosa de palabras de alta y baja frecuencia.

En términos más generales, Hanslmayr et al. [35] destacan el rol de los procesos de desincronización en la banda beta en procesos de recuperación de memoria, que son compatibles con los procesos de traducción. Es posible argumentar que la exigencia de los procesos de recuperación de memoria es mayor en tareas de traducción que en tareas de lectura, teniendo en cuenta que las primeras involucran dinámicas interlingüísticas que van desde la coactivación hasta la necesidad de inhibir candidatos léxicos de una de las dos lenguas [4]. Estos procesos no se manifiestan en tareas de lectura, que son exclusivamente monolingües. Más específicamente, el acceso a los equivalentes de traducción requiere una mayor demanda de recuperación de memoria cuando la traducción se realiza de L1 a L2 en comparación con la traducción realizada en la dirección contraria. Esto se debe a que, en FTR, la palabra buscada pertenece a L2, un dominio menos consolidado en la memoria de bilingües tardíos, si se lo compara con la información almacenada en L1, con la cual la persona bilingüe ha tenido contacto desde sus primeros instantes de vida [4]. En línea con este resultado, Hanslmayr et al. [36] concluyen que la codificación semántica de palabras muestra un grado de desincronización en regiones frontales dentro de la banda beta, asociado al procesamiento de las características del elemento que se debía recordar.

Por otra parte, la ausencia de resultados en una ventana temporal temprana (0-300 ms) es esperable, considerando que no existen trabajos previos en el área que hayan reportado resultados significativos en esta ventana temporal vinculados a tareas de procesamiento de palabras, tanto en lo que hace a lectura como a traducción. Aquí, a modo exploratorio, se incluyó dicha ventana temporal debido a la escasez de estudios en esta temática. Sin embargo, los resultados obtenidos coincidieron con la falta de evidencia en la bibliografía de modulaciones tempranas.

A su vez, la presencia de resultados significativos únicamente para la comparación FTR vs. BTR muestra que el análisis de frecuencias es sensible a diferencias más amplias, como las que se dan en los procesos de traducción, que involucran varios procesos complejos, pero no logra capturar diferencias más sutiles, como las existentes entre tareas de lectura o de traducción pura (esto es, con el efecto de lectura sustraído).

Además de la modulación en frecuencia, el presente trabajo presenta el primer aporte en relación con la interacción entre respuestas conductuales y modulaciones de frecuencia beta. En particular, se destaca la correlación existente entre el grado de desincronización registrado en la banda beta baja y en la ventana temporal tardía para

BTR y los valores respectivos de RT. Cabe destacar que la correlación obtenida, a pesar de ser positiva ($\rho > 0$), debe interpretarse como una disminución del grado de desincronización a medida que aumenta el RT de los sujetos durante el desarrollo de esa tarea. El único estudio que también exploró la correlación entre respuestas conductuales y patrones en frecuencia encontró una correlación significativa entre el RT y el grado de sincronización observada durante la traducción hacia atrás (BTR) de palabras, aunque la banda de frecuencia involucrada en ese caso fue la banda delta (1-4 Hz) [45]. Es preciso aclarar que el mencionado estudio se enfocó en personas con amplia experiencia en tareas que impliquen reformulación interlingüística (traducción y/o interpretación simultánea), a diferencia del grupo considerado aquí, que incluyó únicamente estudiantes sin experiencia en el ejercicio de esas tareas. Además, las comparaciones estadísticas efectuadas en aquel estudio muestran diferencias entre grupos experimentales con distintos niveles de experiencia en traducción simultánea (concretamente, traductores profesionales con y sin experiencia en esas tareas), pero que fueron evaluados en la misma condición experimental (BTR). Las diferencias observadas en este trabajo, por el contrario, surgen a partir de comparaciones estadísticas hechas entre condiciones experimentales para un mismo grupo de sujetos. El hecho de que sólo se haya obtenido una correlación significativa para la condición BTR puede deberse a que, en países no angloparlantes, la dirección de traducción más frecuentemente ejercitada es hacia atrás [8].

La correlación encontrada parecería contradecir los resultados anteriores: mientras que los efectos hasta aquí expuestos parecen asociar un aumento en el grado de desincronización con una mayor demanda cognitiva, la correlación entre el nivel de desincronización y el RT observada para BTR apunta en la dirección contraria, asignando un mayor nivel de desincronización a las respuestas más rápidas, y, por tanto, que implican una menor demanda cognitiva. No obstante, debe recordarse que los resultados anteriormente reportados en este mismo estudio para los análisis conductuales y de frecuencias se basan en diferencias observadas entre condiciones experimentales, y nada asegura, necesariamente, que deba desestimarse la existencia de una interpretación opuesta para las relaciones observadas entre variables asociadas a una misma condición experimental. De hecho, concretamente en lo que respecta a BTR, Grabner et al. [15] destacan un mayor grado de desincronización para la condición cognitivamente más

sencilla (es decir, la traducción de palabras de alta frecuencia, en comparación con palabras de baja frecuencia).

Por otra parte, el análisis de conectividad aportó evidencia significativa (permutaciones: $p_{con} < 0.01$; $p_{clus} < 0.05$) respecto a las diferencias observadas entre tareas de lectura y direcciones de traducción. Restringiendo el análisis para incluir las conexiones con respuesta estadística más extrema (el 10% con valores t más altos en términos absolutos), se identificaron, en ambos casos, dos patrones topográficos claros: uno de ellos en regiones frontales y otro en regiones temporales y temporo-parietales izquierdas. En términos del vínculo existente entre la separación temporal entre puntos utilizados para generar los símbolos (τ) y la banda de frecuencia de mayor sensibilidad del análisis respectivo, puede concluirse que los efectos registrados ($\tau = 16$ ms) corresponden a respuestas en frecuencia de las bandas theta (1-4 Hz) y el rango inferior de alfa (8-10 Hz). Concretamente, tales efectos se observaron en ventanas temporales tardías, y pusieron de manifiesto un patrón de conectividad más intensa para la condición cognitivamente más exigente (L2R y FTR-L1R, respectivamente).

La evidencia previa asociada a patrones de conectividad en el contexto del procesamiento bilingüe es escasa. No obstante, algunos de los resultados anteriormente reportados ratifican el rol de regiones temporales y parietales izquierdas en el procesamiento de tareas de lectura en L1 y L2. En particular, un estudio de conectividad en imágenes de resonancia magnética funcional [54] destaca la participación de estructuras presentes en el lóbulo parietal superior izquierdo, con patrones de conectividad más intensos durante la lectura de palabras en inglés (L2) en relación con la lectura de palabras en español (L1).

En cuanto a la comparación de tareas de traducción, dos estudios muestran resultados consistentes con los aquí reportados. En primer lugar, un estudio que aborda un análisis de conectividad funcional en datos de fMRI [55] destaca que, en la comparación entre tareas de traducción, aparecen patrones de conectividad funcional entre estructuras presentes en el lóbulo temporal anterior izquierdo y otras estructuras frontales, como el giro frontal inferior y la corteza orbitofrontal. Por otro lado, un estudio de conectividad funcional en registros de iEEG que utilizó la misma métrica, wSMI, [7] destaca el intercambio de información entre regiones frontales, prefrontales y temporales observada durante el procesamiento de FTR, a diferencia de lo observado en BTR, que muestra patrones de conectividad más dispersos a través de regiones frontales, parietales

y temporales. Tales patrones de conectividad diferencial observados entre direcciones de traducción podrían reflejar demandas cognitivas y de control ejecutivo más importantes en FTR, que, en última instancia, involucran regiones cerebrales más específicas, vinculadas con diferentes mecanismos léxicos y perceptuales.

Además, la ausencia de resultados en ventana temporal temprana (0-300 ms) también se alinea con la evidencia previa en el campo, puesto que ningún estudio logró capturar un efecto en esta ventana temporal para ninguna tarea que involucre procesamiento bilingüe. Al igual que con el análisis de frecuencias, la intención de incluir esta ventana como parte de esta etapa de análisis fue meramente exploratoria.

En contraste con los resultados obtenidos en el análisis de frecuencias, los análisis de conectividad fueron significativos únicamente para las comparaciones L2R vs L1R y FTR-L1R vs BTR-L2R. Esto indicaría que la conectividad es sensible a dinámicas más sutiles que explican diferencias entre condiciones experimentales más específicas, como la lectura y la traducción, habiéndose eliminado de esta última el efecto de lectura correspondiente.

Por último, la clasificación de ensayos entre condiciones experimentales basada en los resultados en frecuencia y conectividad no logró un desempeño significativo. Este fenómeno podría ser consecuencia del hecho de que la medición de la actividad cerebral realizada con EEG es indirecta, lo que requeriría un número mayor de registros (o, en todo caso, un registro de actividad específica subcortical, que es muy difícil de lograr con esta técnica) para brindar una estimación consistente y robusta del poder predictivo de los resultados obtenidos en términos de clasificación de condiciones experimentales. Por otro lado, la mayoría de los clasificadores aquí reportados, con excepción del análisis de discriminante cuadrático, son esencialmente lineales (en sentido estricto para los clasificadores por discriminante lineal y por vectores de soporte lineal, y aproximado en el caso del clasificador por vecinos más cercanos, debido al valor de k utilizado). Esto implica que los resultados obtenidos solo sirven para descartar la relación lineal entre las variables medidas y las condiciones experimentales, pero no son suficientes para negar relaciones más complejas entre los datos. En este contexto, se prefirió reducir el problema a un análisis lineal (o, a lo sumo, cuadrático) porque es más fácilmente interpretable y porque hay mayor evidencia reportada para este tipo de clasificadores en aplicaciones neurocientíficas [41]. Como línea de investigación a futuro, sería interesante analizar el desempeño de clasificadores no lineales sobre estos mismos conjuntos de datos, para

determinar si ellos son capaces de captar las diferencias entre condiciones experimentales que escaparon a los métodos lineales utilizados en este trabajo.

Conclusiones

El presente trabajo representa un aporte novedoso para la caracterización de las dinámicas de procesos de traducción. Específicamente, provee evidencia respecto de las diferencias observadas entre direcciones de traducción. Este aspecto no había sido previamente explorado a partir de análisis de frecuencia y conectividad. Asimismo, el estudio ratifica los resultados conductuales observados en varios trabajos previos del área. La ausencia de resultados de clasificación en base a los clasificadores utilizados plantea nuevos desafíos a futuro, como la posibilidad de explorar relaciones no lineales que expliquen las diferencias significativas observadas con los otros métodos de análisis reportados.

Las herramientas de análisis utilizadas en este trabajo constituyen un enfoque metodológico original para el abordaje de la temática bilingüe. Específicamente, el uso de una métrica de conectividad no lineal, como wSMI, que capta dinámicas no registradas por técnicas lineales clásicas y que no ha sido utilizada más que de forma incipiente para la caracterización del procesamiento bilingüe, es una de las principales novedades que aporta este estudio. Combinando esto con la utilización de medidas oscilatorias y métodos de aprendizaje estadístico, el presente trabajo muestra de qué manera el desarrollo de herramientas metodológicas sofisticadas puede asistir en la resolución de problemáticas e interrogantes que surgen en un área de conocimiento específico. Esta interdisciplinariedad es uno de los pilares que robustecen el avance de la ciencia.

Referencias

1. García-Pentón, L., et al., *The neuroanatomy of bilingualism: how to turn a hazy view into the full picture*. Language, Cognition and Neuroscience, 2016. **31**(3): p. 303-327.
2. Moreno, E., A. Rodríguez-Fornells, and M. Laine, *Event-related potentials (ERPs) in the study of bilingual language processing*. Journal of Neurolinguistics, 2008. **21**: p. 477-508.
3. Costa, A. and N. Sebastián-Gallés, *How does the bilingual experience sculpt the brain?* (1471-0048 (Electronic)).
4. García, A.M. and S.G. Suárez Cepeda, *Mente bilingüe: Abordajes psicolingüísticos y cognitivistas*. 2016.
5. Cook, V., *Effects of the second language on the first*. Vol. 3. 2003: Multilingual Matters.

6. Cohen, M.X., *Analyzing Neural Time Series Data: Theory and Practice*. 2014: The MIT Press.
7. García, A., E. Mikulan, and A. Ibanez, *A neuroscientific toolkit for translation studies*. 2016. p. 21-46.
8. García, A.M., *The neurocognition of translation and interpreting*. Vol. 147. 2019: John Benjamins Publishing Company Amsterdam/Philadelphia.
9. Janyan, A., I. Popivanov, and E. Andonova, *Concreteness effect and word cognate status: ERPs in single word translation*. Brain talk: Discourse with and in the brain, 2009.
10. Steriade, M., *Grouping of brain rhythms in corticothalamic systems*. (0306-4522 (Print)).
11. Curio, G., *Linking 600-Hz 'spikelike' EEG/MEG wavelets (' σ -bursts') to cellular substrates: Concepts and caveats*. Journal of clinical neurophysiology : official publication of the American Electroencephalographic Society, 2000. **17**: p. 377-96.
12. Klimesch, W., et al., *Event-related desynchronization in the alpha band and the processing of semantic information*. Brain Res Cogn Brain Res, 1997. **6**(2): p. 83-94.
13. Bastiaansen, M.C.M., J.J.A. van Berkum, and P. Hagoort, *Event-related theta power increases in the human EEG during online sentence processing*. Neuroscience Letters, 2002. **323**(1): p. 13-16.
14. Kielar, A., et al., *Oscillatory responses to semantic and syntactic violations*. J Cogn Neurosci, 2014. **26**(12): p. 2840-62.
15. Grabner, R.H., et al., *Event-related EEG theta and alpha band oscillatory responses during language translation*. Brain Research Bulletin, 2007. **72**(1): p. 57-65.
16. Sporns, O. *Networks of the Brain: Quantitative Analysis and Modeling*. 2010.
17. Friston, K.J., *Functional and effective connectivity in neuroimaging: A synthesis*. Human Brain Mapping, 1994. **2**(1-2): p. 56-78.
18. King, J.R., et al., *Information sharing in the brain indexes consciousness in noncommunicative patients*. Curr Biol, 2013. **23**(19): p. 1914-9.
19. Melloni, M., et al., *Cortical dynamics and subcortical signatures of motor-language coupling in Parkinson's disease*. Scientific reports, 2015. **5**: p. 11899-11899.
20. Dottori, M., et al., *Towards affordable biomarkers of frontotemporal dementia: A classification study via network's information sharing*. Sci Rep, 2017. **7**(1): p. 3822.
21. Sitt, J.D., et al., *Large scale screening of neural signatures of consciousness in patients in a vegetative or minimally conscious state*. Brain : a journal of neurology, 2014. **137**(Pt 8): p. 2258-2270.
22. Birba, A., et al., *Motor-system dynamics during naturalistic reading of action narratives in first and second language*. 2020. **216**: p. 116820.
23. Glaser, J.I., et al., *The roles of supervised machine learning in systems neuroscience*. 2019. **175**: p. 126-137.
24. James, G., et al., *An introduction to statistical learning : with applications in R*. Springer texts in statistics,. 2013, New York: Springer. xvi, 426 pages.
25. Hastie, T., R. Tibshirani, and J.H. Friedman, *The elements of statistical learning : data mining, inference, and prediction*. 2nd ed. Springer series in statistics,. 2009, New York, NY: Springer. xxii, 745 p.
26. García, A.M., et al., *Word reading and translation in bilinguals: the impact of formal and informal translation expertise*. Frontiers in psychology, 2014. **5**: p. 1302-1302.
27. Davies, M., *Corpus del Español: 100 million words, 1200s-1900s*. 2002.
28. Davies, M.J.L. and I. computing, *The Corpus of Contemporary American English as the first reliable monitor corpus of English*. 2010. **25**(4): p. 447-464.
29. Love, J., et al., *JASP: Graphical statistical software for common statistical designs*. 2019. **88**(2): p. 1-17.
30. MATLAB. The MathWorks Inc., <http://www.mathworks.com/>: Natick, Massachusetts, USA.
31. Delorme, A. and S.J.J.o.n.m. Makeig, *EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics including independent component analysis*. 2004. **134**(1): p. 9-21.

32. Oostenveld, R., et al., *FieldTrip: Open source software for advanced analysis of MEG, EEG, and invasive electrophysiological data*. Comput Intell Neurosci, 2011. **2011**: p. 156869.
33. Bastiaansen, M.C.M., et al., *Theta Responses Are Involved in Lexical—Semantic Retrieval during Language Processing*. Journal of Cognitive Neuroscience, 2005. **17**(3): p. 530-541.
34. Davidson, D.J. and P. Indefrey, *An inverse relation between event-related and time–frequency violation responses in sentence processing*. Brain Research, 2007. **1158**: p. 81-92.
35. Hanslmayr, S., T. Staudigl, and M.C. Fellner, *Oscillatory power decreases and long-term memory: the information via desynchronization hypothesis*. Front Hum Neurosci, 2012. **6**: p. 74.
36. Hanslmayr, S., K.-H. Spitzer B Fau - Bäuml, and K.H. Bäuml, *Brain oscillations dissociate between semantic and nonsemantic encoding of episodic memories*. (1460-2199 (Electronic)).
37. Vilas, M.G., et al., *Reading Shakespearean tropes in a foreign tongue: Age of L2 acquisition modulates neural responses to functional shifts*. Neuropsychologia, 2019. **124**: p. 79-86.
38. Hald, L.A., M.C. Bastiaansen, and P. Hagoort, *EEG theta and gamma responses to semantic violations in online sentence processing*. Brain Lang, 2006. **96**(1): p. 90-105.
39. Willems, R.M., R. Oostenveld, and P. Hagoort, *Early decreases in alpha and gamma band power distinguish linguistic from visual information during spoken sentence comprehension*. Brain Res, 2008. **1219**: p. 78-90.
40. Maris, E. and R. Oostenveld, *Nonparametric statistical testing of EEG- and MEG-data*. J Neurosci Methods, 2007. **164**(1): p. 177-90.
41. Hesse, E., et al., *Consistent gradient of performance and decoding of stimulus type and valence from local and network activity*. 2019. **27**(4): p. 619-629.
42. Python. Python Software Foundation, <https://www.python.org/>.
43. Pedregosa, F., et al., *Scikit-learn: Machine learning in Python*. 2011. **12**: p. 2825-2830.
44. Dehaene, S. and J.-R.J.M.-. King, *meso- and macro-dynamics of the brain, Decoding the Dynamics of Conscious Perception: The Temporal Generalization Method*. 2016: p. 85-97.
45. Dottori, M., et al., *Task-specific signatures in the expert brain: Differential correlates of translation and reading in professional interpreters*. Neuroimage, 2020. **209**: p. 116519.
46. Santilli, M., et al., *Bilingual memory, to the extreme: Lexical processing in simultaneous interpreters*. Bilingualism: Language and Cognition, 2019. **22**(2): p. 331-348.
47. Jost, L.B., et al., *Behavioral and electrophysiological signatures of word translation processes*. Neuropsychologia, 2018. **109**: p. 245-254.
48. Klein, D., et al., *The neural substrates underlying word generation: a bilingual functional-imaging study*. Proceedings of the National Academy of Sciences, 1995. **92**(7): p. 2899.
49. Rinne, J.O., et al., *The translating brain: cerebral activation patterns during simultaneous interpreting*. Neuroscience Letters, 2000. **294**(2): p. 85-88.
50. Tommola, J., et al., *Images of shadowing and interpreting*. 2000. **5**(2): p. 147-167.
51. Christoffels, I.K., L. Ganushchak, and D. Koester, *Language conflict in translation: An ERP study of translation production*. Journal of Cognitive Psychology, 2013. **25**(5): p. 646-664.
52. Kurz, I.J.T.s.A.i., *A look into the 'black box'—EEG probability mapping during mental simultaneous interpreting*. 1994. **2**: p. 199.
53. Kroll, J.F., E.J.J.o.m. Stewart, and language, *Category interference in translation and picture naming: Evidence for asymmetric connections between bilingual memory representations*. 1994. **33**(2): p. 149.
54. Pérez, A., et al., *Complex brain network properties in late L2 learners and native speakers*. 2015. **68**: p. 209-217.

55. Zheng, B., et al., *Semantic and attentional networks in bilingual processing: fMRI connectivity signatures of translation directionality*. 2020. **143**: p. 105584.

Anexo

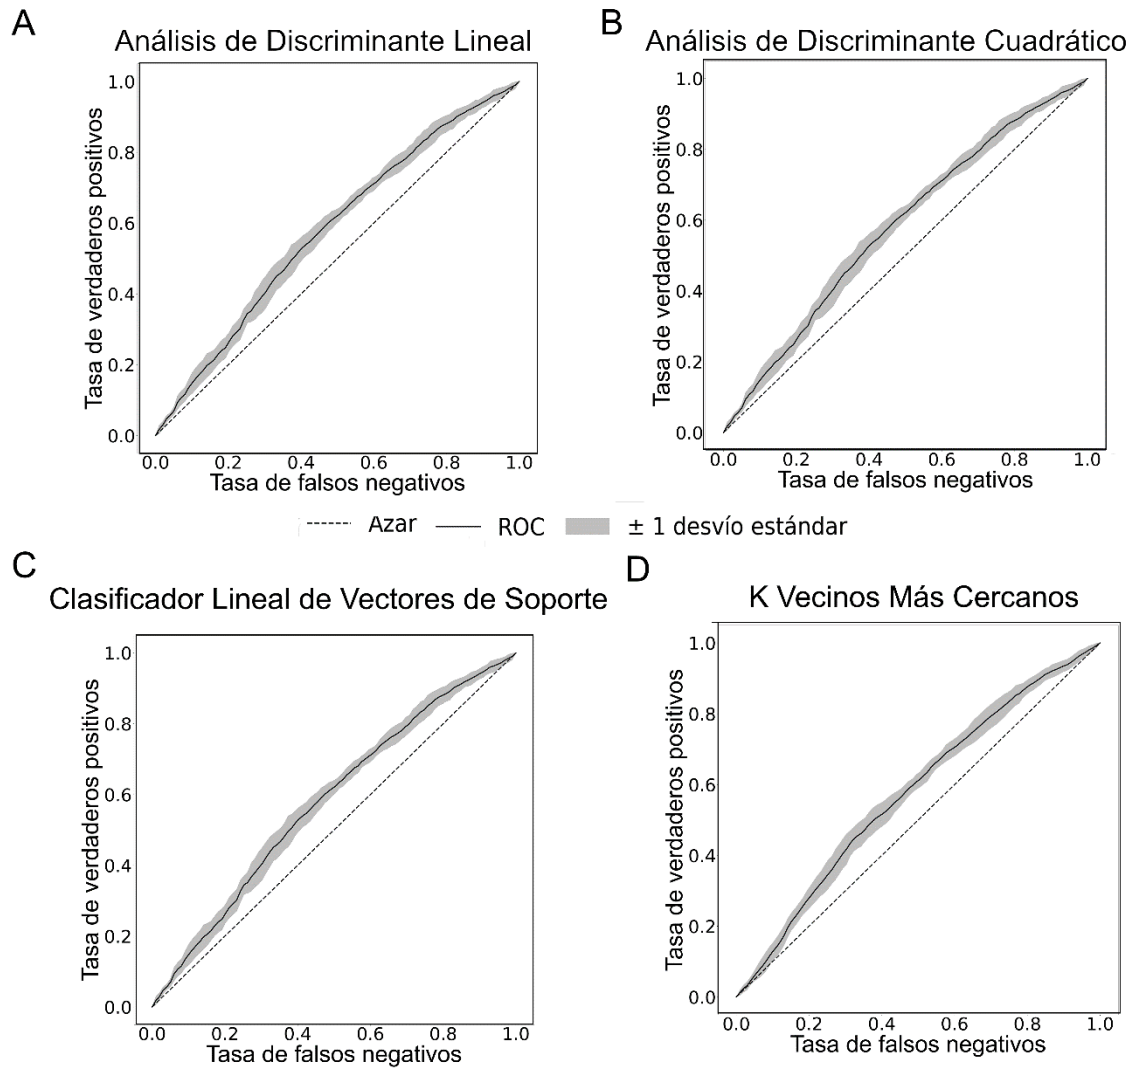


Figura 8. Clasificación entre L2R y L1R basada en el valor medio de wSMI de los clústeres significativos correspondientes a $\tau = 16$ ms. Se muestran las curvas ROC medias de cada clasificador a lo largo de los 10 pasos de validación cruzada (*10-Folds Cross-Validation*) implementados, junto con el desvío estándar correspondiente. En línea punteada se destaca la curva ROC de un clasificador por azar ($AUC = 0.5$) (A) Análisis de Discriminante Lineal ($AUC = 0.594 \pm 0.020$); (B) Análisis de Discriminante Cuadrático ($AUC = 0.594 \pm 0.020$); (C) Clasificador Lineal de Vectores de Soporte ($AUC = 0.594 \pm 0.020$); (D) K Vecinos Más Cercanos ($K = 317$) ($AUC = 0.589 \pm 0.023$).

Glosario

ANOVA: análisis de varianza.

AUC: área bajo la curva ROC.

BTR: traducción hacia atrás (de L2 a L1).

dB: decibeles.

EEG: electroencefalografía.

ERP: potenciales evocados.

FFT: Transformada Rápida de Fourier.

fMRI: imágenes de resonancia magnética funcional.

FTR: traducción hacia adelante (de L1 a L2).

iEEG: electroencefalografía intracraneal.

L1: lengua nativa.

L1R: lectura en L1.

L2: lengua no nativa.

L2R: lectura en L2.

ROC: curva de característica operativa del receptor.

RT: tiempo de reacción.

SMI: información simbólica mutua.

TNR: razón de verdaderos negativos.

TPR: razón de verdaderos positivos.

wSMI: información simbólica mutua ponderada.